군-학 연계 프로그램 범용 교육

RAG 챗봇 — 내 문서에 답하는 AI, 문서 질의응답 시스템

서왕덕

경기대학교 AI컴퓨터공학부 3차시

26.09.30



목차

1. 실습 준비: Google 계정과 Colab
2. 복습과 로드맵
3. 1부. 왜 RAG인가: AI는 우리 문서를 모른다
4. 2부. RAG 구조: 자르기, 숫자로, 찾기, 답하기
5. 3부. 직접 조립: 찾고, 붙이고, 물어보기
6. 4부. 챗봇 완성: 자동으로 답하고, 틀리는 곳을 찾는다
7. 5부. 운영과 보안: 어떤 문서를, 어디에
8. 6부. 내 PC에서 답하기: Ollama
9. 정리



실습 준비

Google 계정 만들기와 Colab 열기

오늘의 도구 3개

claude.ai
1차시에 만든 계정 그대로. 오늘은 "답하는 쪽"을 맡는다

Google 계정
오늘 새로 만든다. Colab에 들어가는 열쇠. 5,6,7차시에도 쓴다

Colab
브라우저 안에서 파이썬을 실행해 주는 무료 공책. 설치할 것이 없다

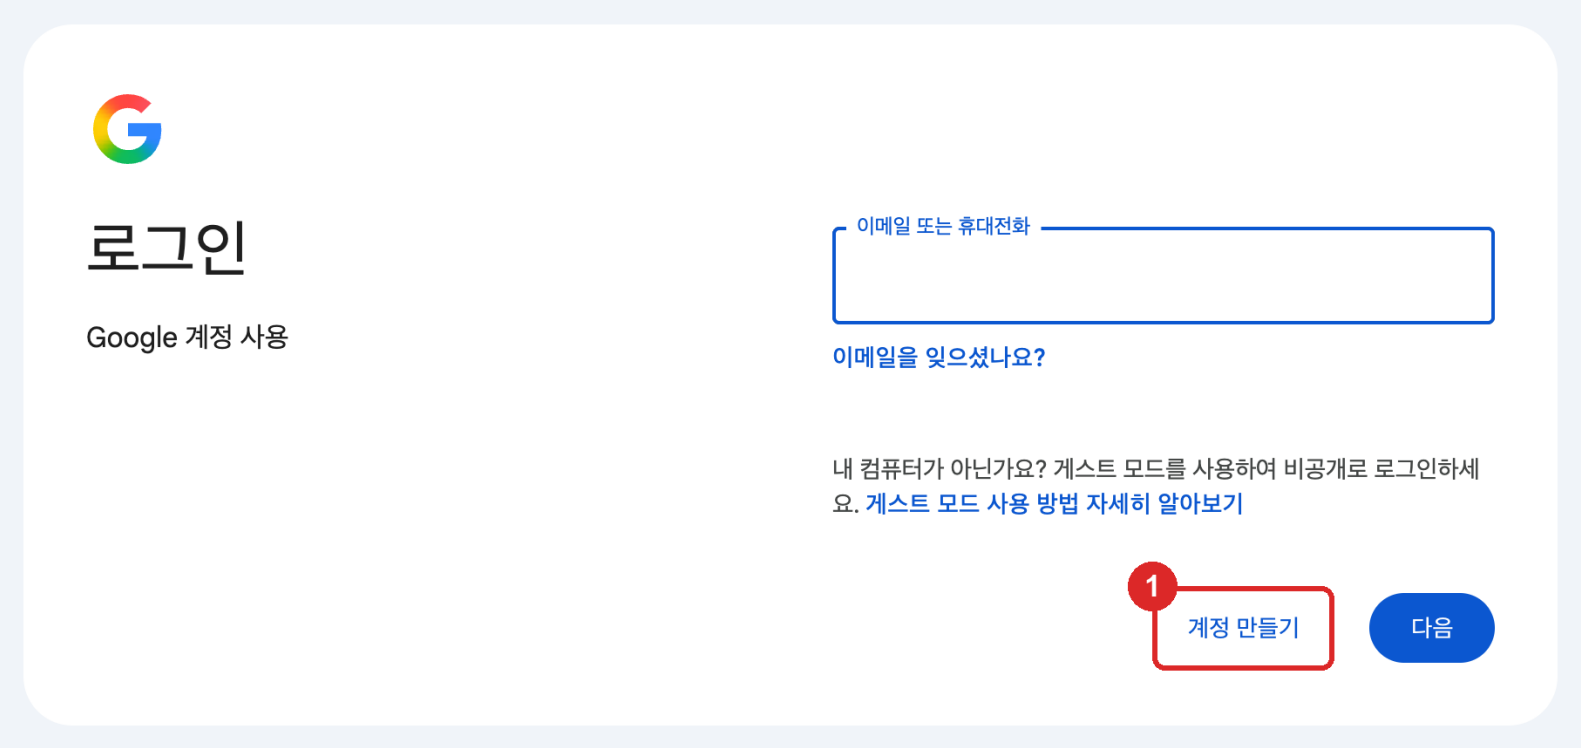
왜 Colab인가

내 PC에 아무것도 깔지 않는다. 무료다. 실습실 PC가 초기화돼도 결과는 Google Drive에 남는다. 딥러닝을 배우는 뒤 차시에서도 같은 화면을 쓴다.

가입 전에 확인

Google 가입은 **휴대폰 문자 인증**을 요구할 수 있다. 휴대폰을 옆에 둔다. 이미 Google 계정(Gmail)이 있으면 새로 만들지 않고 **로그인만** 한다.

Google 계정 만들기 1: 시작



순서

1 브라우저 주소창에 `accounts.google.com` 입력 2 로그인 화면의 **계정 만들기**(그림의 빨간 1번) 클릭 3 **개인용** 선택

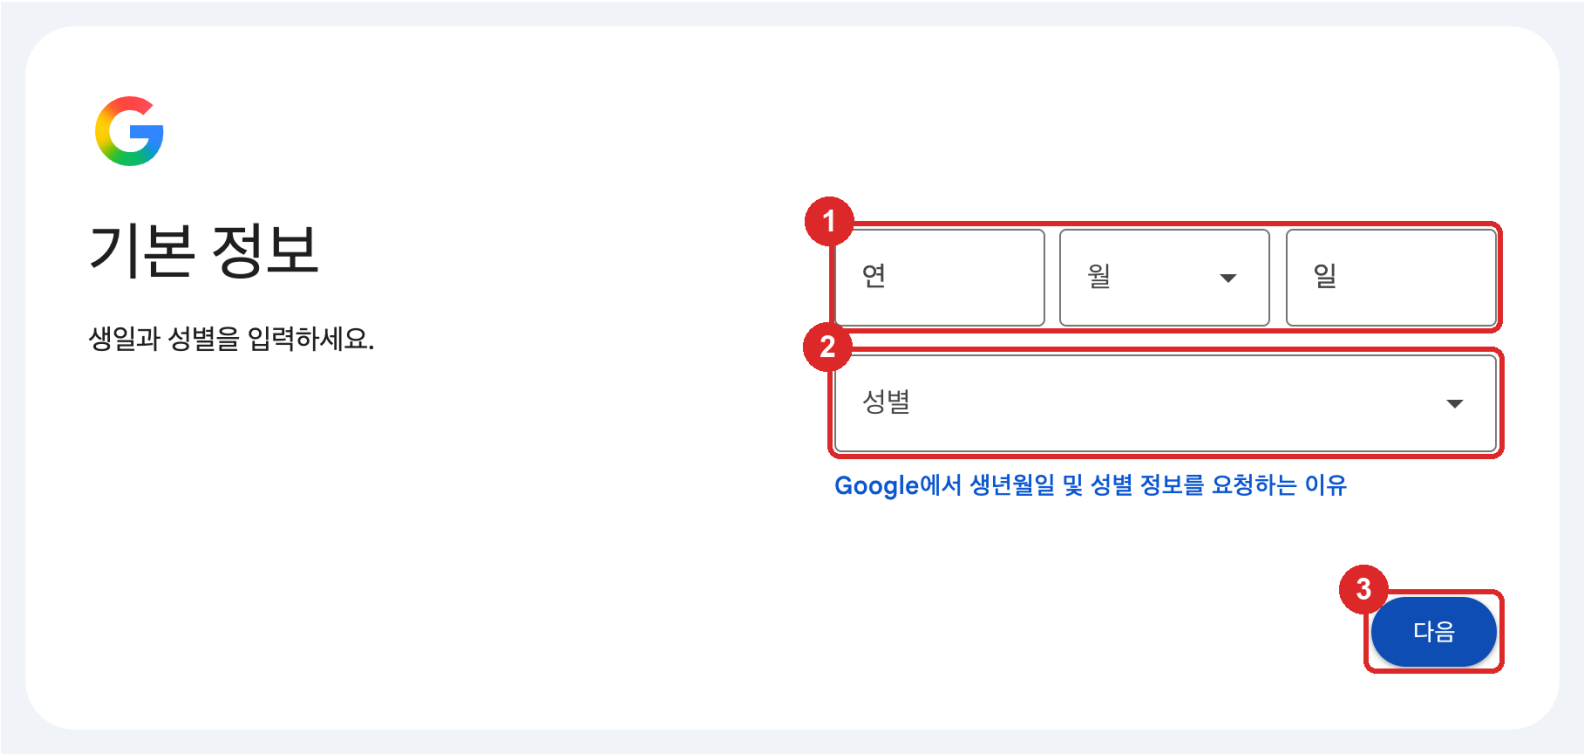
Google 계정 만들기 2: 이름



순서

1 **이름**만 필수. 성은 비워도 되고, 닉네임도 된다 2 **다음**

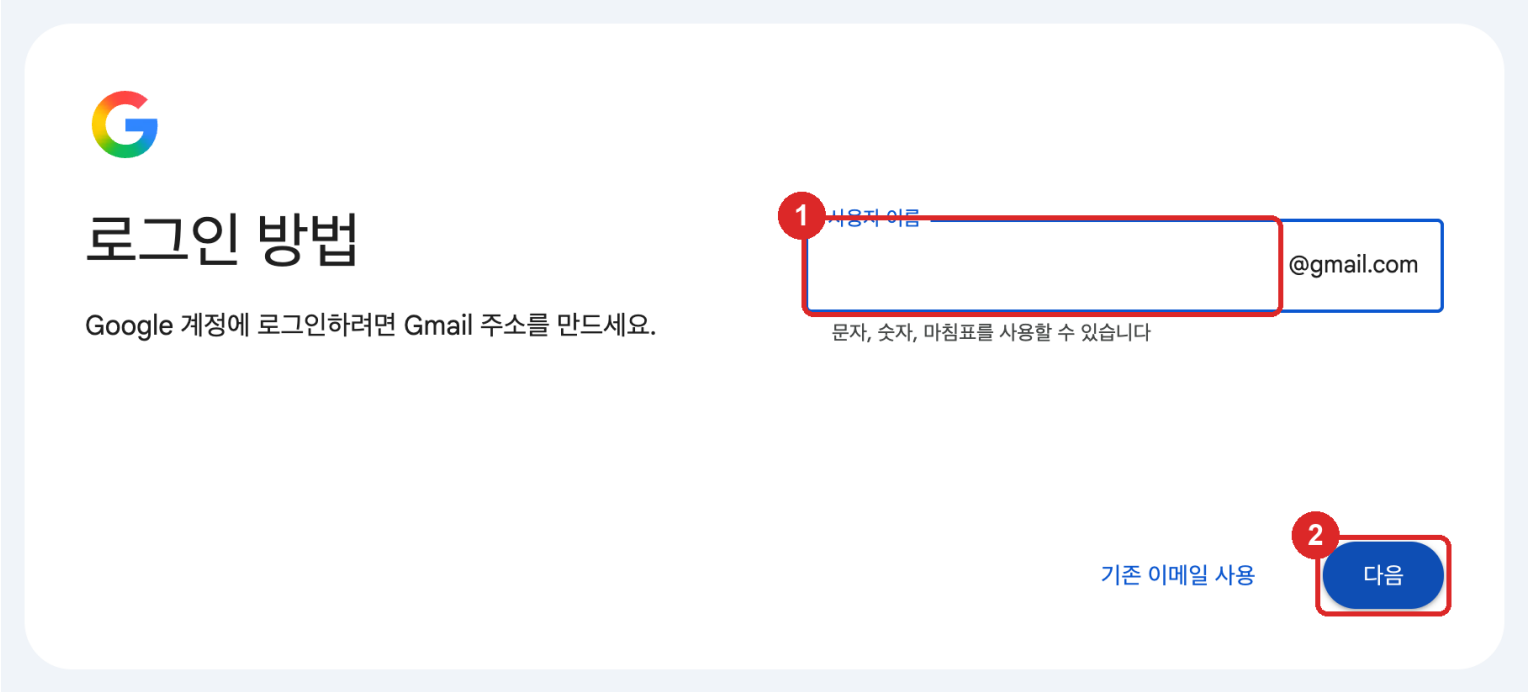
Google 계정 만들기 3: 생년월일 · 성별



순서

1. 생년월일은 **실제**로 넣는다(나이 확인용)
2. 성별은 "공개 안함"도 된다
3. **다음**

Google 계정 만들기 4: 주소

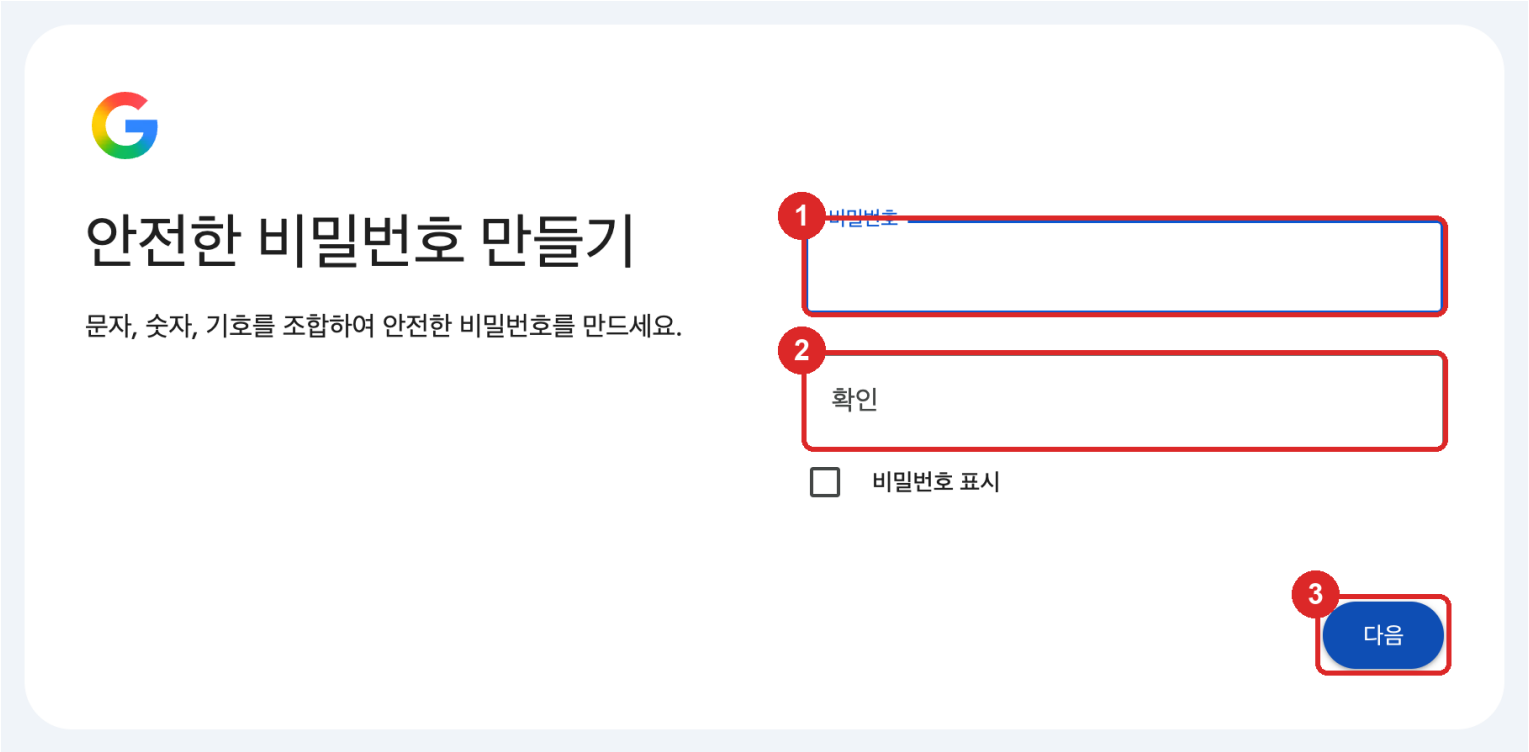


순서

1 원하는 **아이디**를 입력한다: 소문자 · 숫자 · 마침표, 6자 이상. 이미 있는 주소면 빨간 글씨가 뜬다 → 다른 것으로 2 **다음**

제안 주소 2개와 "내 Gmail 주소 만들기"가 보이는 화면이 대신 나오기도 한다. 어느 쪽이든 아이디 하나를 정하면 된다.

Google 계정 만들기 5: 비밀번호



순서

1 8자 이상, 문자와 숫자를 섞는다 2 같은 것을 한 번 더 3 **다음**. 주소와 비밀번호를 **종이에 적어 둔다** — 수업 중 다시 로그인한다

Google 계정 만들기 6: 전화 인증 · 완료

화면 캡처 자리
`figs/g06_phone.png`
전화번호 인증 화면 (수업 전 강사 캡처)

남은 순서

1) 휴대폰 번호 입력 → 다음
2) 문자로 온 **6자리 코드** 입력
3) 복구 이메일은 **건너뛰기**
4) 계정 정보 확인 → 다음
5) 개인정보 · 약관 **동의** → 완료

인증 문자가 안 오면

60초 뒤 "다시 보내기". 번호 하나로 만들 수 있는 계정 수가 제한되니 남의 번호를 빌리지 않는다. 그래도 안 되면 손을 든다 — 조교 계정으로 실습하고 집에서 가입한다. 브라우저에 따라 전화번호 대신 **휴대폰으로 QR 코드를 찍는 확인 화면**이 나올 수 있다. 화면 안내대로 찍으면 다음으로 넘어간다.

오른쪽 위에 **동그란 프로필 아이콘**이 보이면 로그인된 것이다. 다음 슬라이드의 체크리스트로 간다.

실습 0-1: Google 계정 체크리스트 (7분)

prompts/01_google_colab_setup.txt — 가입 순서 전문과 안 될 때 표

하나씩 눈으로 확인

✓ accounts.google.com에서 "계정 만들기" → 개인용으로 시작했다
✓ 이름 · 생년월일 · 주소 · 비밀번호를 넣고 문자 인증을 통과했다
✓ 새 주소(아이디@gmail.com)와 비밀번호를 종이에 적었다
✓ 화면 오른쪽 위에 프로필 아이콘이 보인다(로그인 상태)
✓ 브라우저의 "비밀번호 저장" 제안은 **거절**했다(공용 PC)

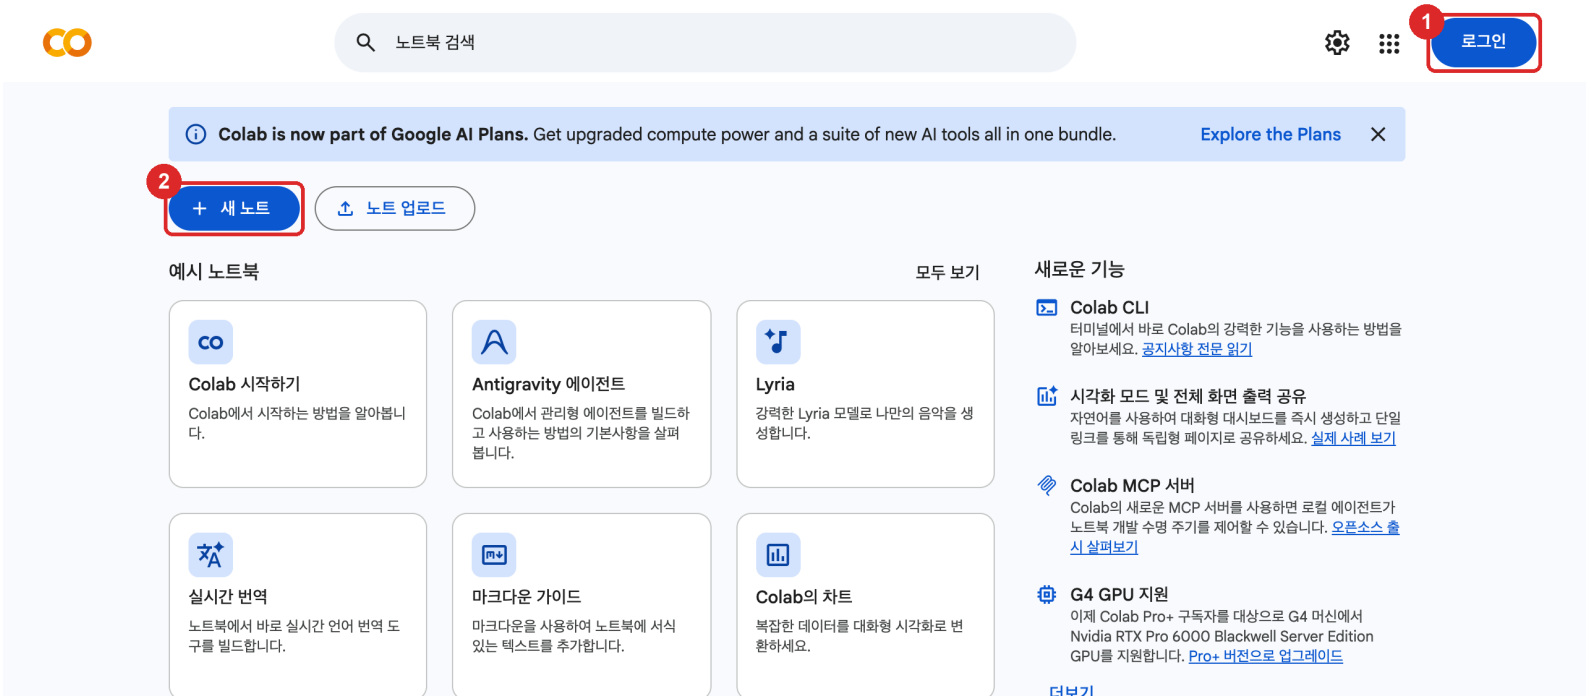
5분 규칙

5분 넘게 막히면 손을 든다. 가입은 옆에서 화면을 한 번 보는 것이 가장 빠르다. 화면의 빨간 글씨는 **그대로** 읽어 준다.

이미 계정이 있는 사람

로그인만 하고 기다린다. 기다리는 동안 colab.research.google.com을 열어 둔다(다음 슬라이드).

Colab이란: 브라우저 안의 파이썬 공책



Colab (colab.research.google.com)

브라우저 안에서 파이썬을 실행해 주는 Google의 무료 공책. **노트북** = 셀(상자)들의 목록, **셀** = 코드 + 그 결과, ▶ = 실행. 설치 없음, 무료, PC가 초기화돼도 Drive에 남는다. 그림의 1 로그인으로 들어간다. 2 새 노트는 오늘 안 쓴다(링크로 연다).

오늘 노트북 열기



순서

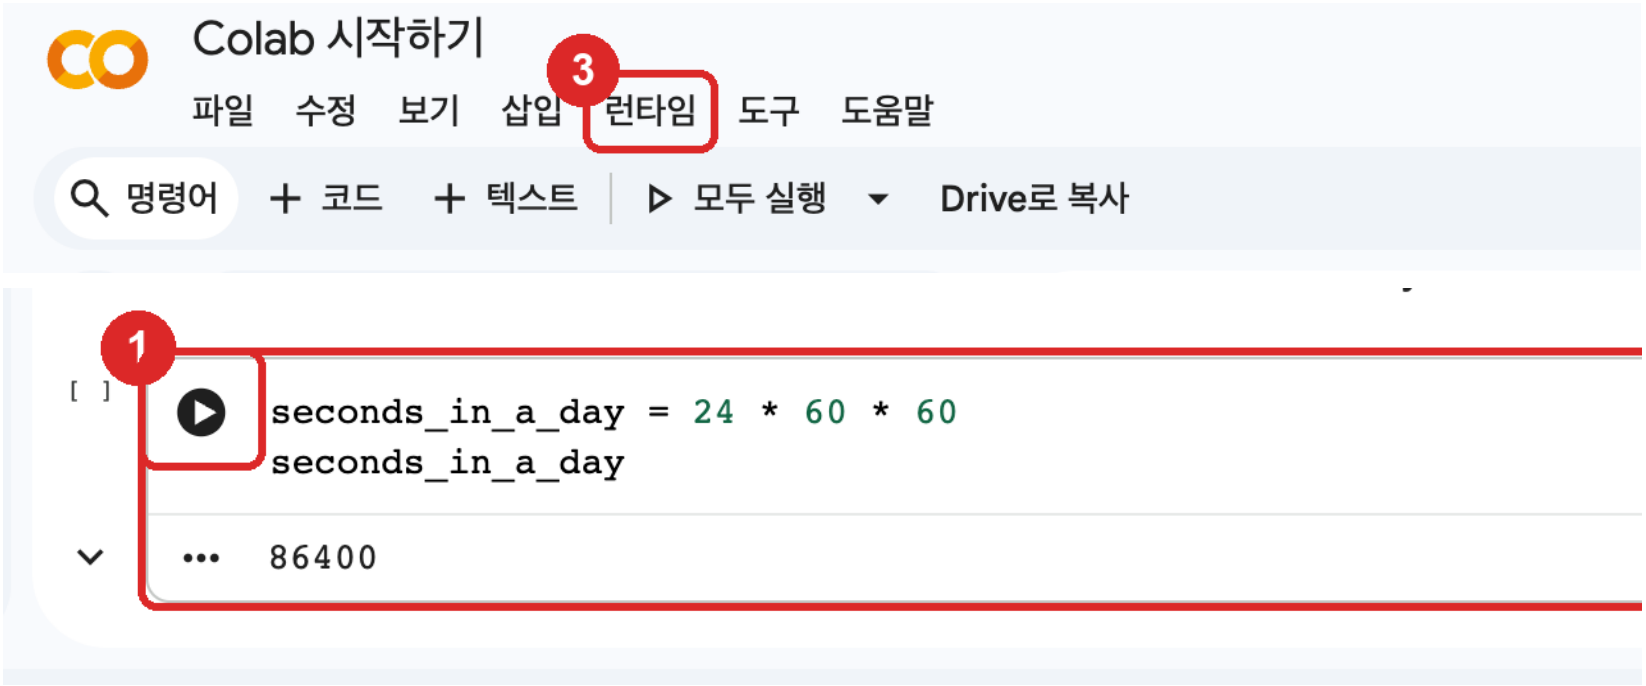
1) 강사가 알려 주는 **노트북 링크**를 브라우저에 입력한다
2) Google 로그인을 물으면 방금 만든 계정으로
3) 위 메뉴 **1** **파일** → **2** **Drive에 사본 저장**
4) 제목이 "...의 사본"으로 바뀌면 내 것. 이제 실행한다

노트북 링크

[노트북 링크] 파일 이름 `rag_chatbot.ipynb`. 링크가 안 열리면 **파일** → **노트 업로드**로 조교가 준 파일을 올린다.

⚠ **사본을 안 만들면**: 원본은 읽기 전용이라 실행은 돼도 저장이 안 된다. 제목에 "사본"이 있는지 먼저 본다.

노트북 화면 읽는 법

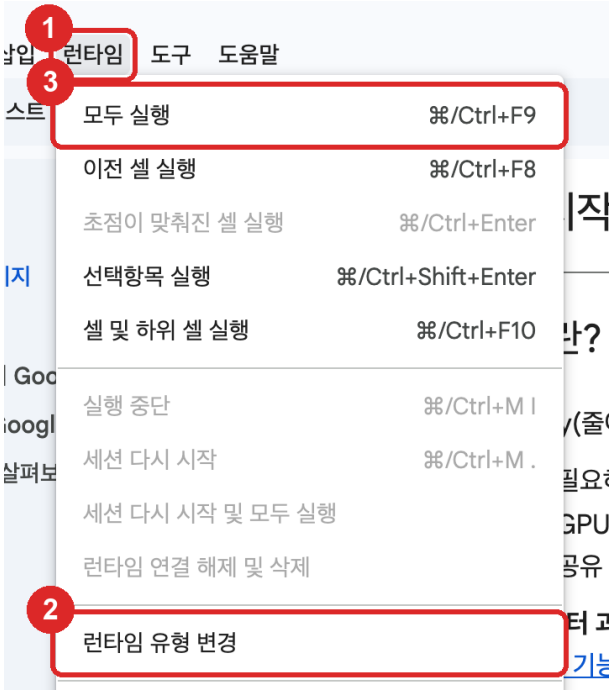


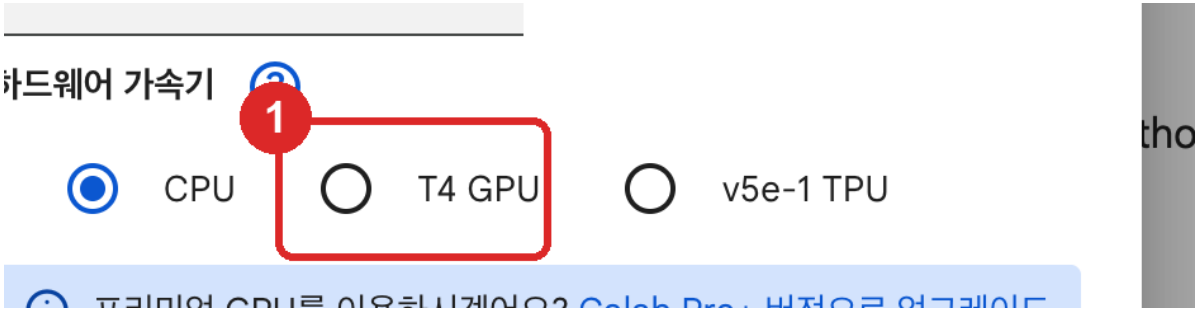
네 가지만 알면 된다

1 셀 왼쪽의 ▶: 이 셀을 실행한다. 빙글빙글 도는 동안은 실행 중 2 셀 = 회색 상자 하나. 끝나면 왼쪽 [ ]에 순서 숫자가 생기고, 결과는 셀 **바로 아래**에 찍힌다(그림의 86400)

3 위 메뉴의 **런타임**: 모두 실행, GPU 설정. 코드는 한 글자도 안 친다.

GPU 켜기 (선택)





순서

1 메뉴 **런타임** → 2 **런타임 유형 변경** → 하드웨어 가속기에서 **T4 GPU** → **저장**. 3 **모두 실행**은 셀을 위에서 아래로 한 번에 돌린다(오늘은 하나씩).

GPU가 안 잡히면

무료라 보장이 없다. "GPU 백엔드에 연결할 수 없습니다"가 뜨면 **CPU 그대로** 진행한다. 4부 실습 5(셀 7)만 건너뛴다. 나머지는 전부 CPU로 된다.

실습 0-2: 노트북 준비 체크리스트 (8분)

prompts/01_google_colab_setup.txt — 2부 "Colab 열기"

하나씩 눈으로 확인

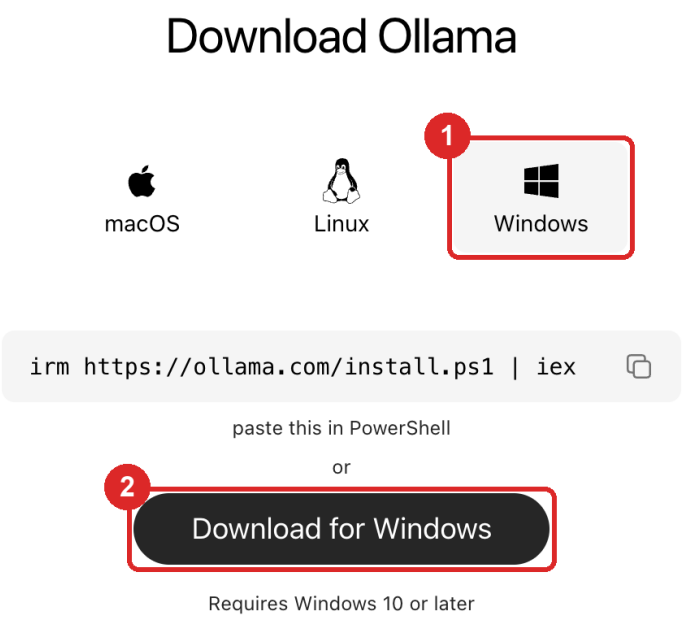
✓ 노트북 제목 앞에 "사본"이 붙어 있다
✓ 셀 1의 ▶를 눌러 "준비 완료"가 아래에 찍혔다
✓ 다른 탭에 claude.ai를 열고 1차시 계정으로 로그인했다
✓ 규정집 파일은 노트북 안에 들어 있다 — **업로드할 것 없음**

화면에 뜬 말	원인	조치
"런타임에 연결할 수 없습니다"	서버 혼잡	30초 뒤 ▶ 다시. 그래도 안 되면 런타임 → 다시 연결
파일 메뉴에 "사본 저장"이 없음	로그인 안 됨	오른쪽 위 "로그인" → 새 계정으로
▶를 눌렀는데 아무 반응 없음	클릭이 안 됨	셀 안을 한 번 클릭한 뒤 ▶를 정확히 누른다

5분 규칙은 여기도 같다. 준비가 끝난 사람은 옆 사람 화면을 봐 준다.

실습 0-3: Ollama 설치 (4분)

`prompts/10_ollama_local.txt` — 1) 설치 파일 받기 · 2) 설치



순서

1) 브라우저 새 탭에 `ollama.com/download`

2) 빨간 **1 Windows** → 빨간 **2 Download for Windows**

3) 다운로드 폴더의 `OllamaSetup.exe` 두 번 클릭 → **Install**. 관리자 비밀번호는 묻지 않는다

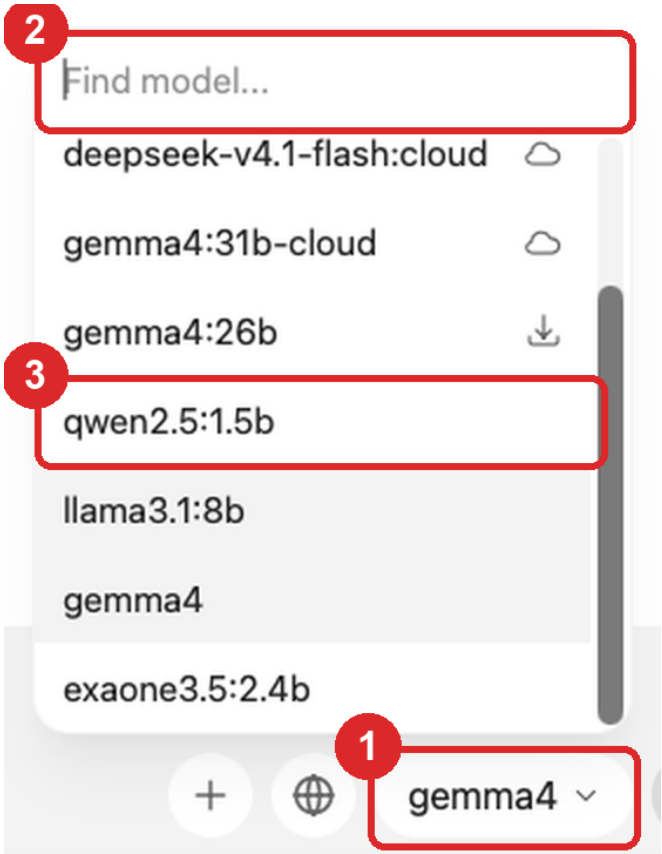
4) 1~2분 뒤 **Ollama 앱**(라마 그림) 창이 뜨면 끝. 작업 표시줄 오른쪽 아래에 라마 아이콘

필요한 것 · 왜 지금

Windows 10 22H2 이상, 빈 공간 약 4GB. GPU 없어도 된다. 파일이 커서 시간이 걸리므로 **수업 앞에서** 받아 둔다. 6부에서 쓴다.

실습 0-4: 모델 받기 (3분, 내려받기는 뒤에서 계속)

prompts/10_ollama_local.txt — 3) 모델 받기



앱에서

1) 입력창 오른쪽 아래 **모델 이름 버튼**(빨간 1) 클릭

2) `Find model`(빨간 2)에 `qwen2.5:1.5b` 입력

3) 목록에서 `qwen2.5:1.5b`(빨간 3) 클릭. 아직 없는 모델엔 내려받기 화살표가 붙어 있다

4) 입력창에 "안녕"을 보내면 내려받기 시작 (986MB, 몇 분). 다 받히면 답이 온다

명령어로도 같다

`ollama pull qwen2.5:1.5b` — 6부에서 본다. 셀 7과 **같은 모델**이다. 내려받는 동안 수업을 계속한다. 다 받혔는지는 6부 실습 9에서 확인.

Ollama 막힐 때 (실습 0-3 · 0-4 · 9)

화면에 뜬 말	원인	조치
설치 창이 안 뜨거나 "지원하지 않는 버전"	Windows 10 22H2 미만	옆 사람 PC로 0-4부터 같이 본다
설치 뒤 앱 창이 안 보임	트레이로 들어감	작업 표시줄 오른쪽 라마 아이콘 클릭, 또는 시작 메뉴 "Ollama"
모델 내려받기가 5분 넘게 돈다	회선 혼잡	그대로 두고 수업을 계속한다. 6부까지 안 받히면 옆 사람 앱으로
`model not found`	이름 철자	`qwen2.5:1.5b` — 점과 콜론 위치 확인
답이 30초 넘게 안 나옴	CPU라 느림 · 메모리 부족	기다린다. 계속 멈추면 더 작은 모델 `gemma3:1b`
답에 한자 · 영어가 섞임	1.5B 모델 특성	같은 프롬프트를 한 번 더. 규칙 4줄은 지우지 않는다

✋ 5분 규칙. 설치가 안 되는 사람은 옆 사람 화면으로 실습 9 체크표를 채운다. 원리를 보는 것이 목적이다.



복습과 로드맵

말하기, 저장하기, 그리고 연결하기

오늘 수업 로드맵 (120분)

시간	구간	내용	실습
22분	실습 준비	Google 계정 · Colab · 노트북 사본 · Ollama 설치 · 모델	실습 0-1∼0-4
6분	복습 · 로드맵	1 · 2차시 연결 · 오늘의 결과물 · 준비 원칙	—
10분	**1부** 왜 RAG인가	세 가지 길 · RAG 정의 · 프로젝트로 맛보기	실습 1
18분	**2부** RAG 구조	자르기 · 숫자로 · 찾기 · 답하기	실습 2
22분	**3부** 직접 조립	검색 결과 읽기 · 붙여넣기로 완성	실습 3 · 4
20분	**4부** 챗봇 완성	자동 답하기 · 챗봇 대화 · 실패 실험	실습 5-8
6분	**5부** 운영 · 보안	올려도 되는 문서 · 내부 구조 · 평가 · 저장	—
10분	**6부** 내 PC에서 답하기	명령어 · 붙여넣기로 답 · 세 생성기 비교	실습 9
6분	정리	핵심 정리 · 집에서 이어하기 · PC 정리	—

◎ 오늘의 목표 하나

규정집에 대해 물으면 **규정집만 근거로** 조항 번호와 함께 답하고, 규정집에 **없으면 없다고** 하는 챗봇을 각자의 Colab에서 완성한다. 실습 프롬프트 전문은 `prompts/` 폴더, 00_README부터.

1차시 프롬프트
잘 묻는 법. 5요소(역할 · 맥락 · 과제 · 형식 · 제약). 맥락은 **내가 써 넣었다**

2차시 스킬
절차와 양식을 파일로 저장. 필요할 때 AI가 읽는다. 자료는 **프로젝트에 첨부**했다

3차시 RAG
자료를 AI에 **연결**한다. 질문마다 필요한 부분을 AI가 스스로 찾아 읽는다

⇄ 2차시의 한 줄을 다시

2차시에서 "프로젝트는 **무엇을 알아야 하나**, 스킬은 어떻게 하나"라고 했다. 오늘은 그 "알아야 할 것"을 사람이 매번 골라 넣는 대신, **AI가 질문에 맞는 부분을 스스로 찾게** 만든다. 그 장치의 이름이 RAG다.

↻ 그대로 가져오는 것

1차시의 환각 · 기억 없음 · 5요소, 2차시의 "자료는 프로젝트에" 원칙과 준비 원칙(개인 계정 · 가상 데이터).

오늘의 결과물: 질문에 답하는 챗봇

```
# 셀 8. 챗봇 — 질문을 받아 답하기를 되풀이합니다 (GPU가 없어도 동작)
while True:
    question = input("질문> ").strip() …

민트상사 규정집 챗봇입니다. 질문을 쓰고 Enter. 끝내려면 빈 칸에서 Enter.

질문>  국내 출장 숙박비 한도는 1박에 얼마인가요?
답: 숙박비의 한도는 1박 80,000원입니다.
[찾은 조각]
  1위  점수 0.89  제15조(국내 출장비)
  2위  점수 0.84  제16조(해외 출장비)
  3위  점수 0.83  제17조(출장 보고)

질문>  주차비는 지원되나요?
답: 규정집에 없습니다.
[찾은 조각]
  1위  점수 0.83  제27조(중식 지원)
  2위  점수 0.83  제28조(자기계발비)
  3위  점수 0.82  제21조(접대비)
질문>
```

완성 기준 3개

✓ 규정집 질문에 **조항 번호**와 함께 답한다

✓ 규정집에 없는 질문에는 "규정집에 없습니다"

✓ 문서를 **내 것으로 바꿔도** 그대로 돌아간다

소재: 민트상사 사내 규정집

가상 회사의 규정집 30개 조항(근무 · 휴가 · 출장 · 경비 · 재택 · 보안 · 복리후생). 일부러 넣어 둔 함정이 있다: **종전 값과 현재 값이 같이 적힌 조항**, 예외 조항, 답이 엉뚱한 장에 있는 질문, 규정집에 없는 질문. 챗봇이 어디서 틀리는지 보기 위한 것이다.

규정집 전문 `docs/mint_rules.txt`, 질문 16개 `docs/questions.txt`. 노트북에는 규정집이 이미 들어 있다.

준비 원칙 (1 · 2차시와 동일)

개인 계정
Google · claude.ai
모두 개인 이메일로

가상 문서
오늘은 민트상사 규정집.
내 문서는 공개 자료만

업무 문서 금지
실제 업무 자료 ·
개인정보는 올리지
않는다

PC 초기화
실습실 PC는 초기화.
노트북은 Drive에 남고,
로그인은 수업 끝에 해제

⚠ 오늘 쓰는 두 서비스는 모두 외부 서버다

Colab의 계산은 Google 서버에서, claude.ai의 답은 Anthropic 서버에서 만들어진다. 올린 파일과 질문은 밖으로 나간다. 그래서 오늘 올리는 것은 **가상 규정집과 공개 문서뿐**이다. 규정집 제24조가 말하는 것이 바로 이것이다.

5분 규칙

5분 넘게 막히면 손을 든다. 에러의 빨간 글씨는 지우지 말고 그대로 둔다.



1부 왜 RAG인가

AI는 우리 문서를 모른다

AI는 우리 회사 규정을 모른다

그냥 물었을 때

질문 "배우자가 출산하면 경조휴가가 며칠인가요?"

답 "일반적으로 배우자 출산휴가는 법정 10일이며, 회사에 따라 추가 휴가를 주기도 합니다. 인사팀에 확인하세요."

⚠ 그럴듯하지만 **우리 규정**이 아니다. 30일 이내 사용, 증빙 7일 같은 조건은 없다.

규정집을 주고 물었을 때

질문 (규정집 첨부) 같은 질문

답 "제10조에 따라 배우자 출산 경조휴가는 10일입니다. 사유 발생일로부터 30일 이내에 사용하고, 증빙은 복귀 후 7일 이내 제출합니다."

✓ 조항 번호, 일수, 기한이 **문서에서** 나왔다.

1차시에서 배운 두 가지가 그대로 원인

기억 없음: AI는 대화창 안의 내용만 본다. 우리 규정집은 대화창에 없다. **환각**: 모르는 것도 유창하게 답한다. 그래서 "모른다"가 아니라 **일반론**이 나온다. 해결은 하나 — 답하기 전에 **문서를 대화창에 넣어 준다**.

우리 문서를 알게 하는 세 가지 길

방법	어떻게	좋은 점	한계
파인튜닝	문서로 모델을 **다시 학습** 시킨다	문서 없이도 답한다	비싸다. 규정이 바뀌면 다시 학습. 출처가 안 남는다
통째로 넣기	질문할 때마다 문서 **전체**를 프롬프트에 붙인다	짧은 문서엔 가장 정확	문서가 길면 한도 초과 · 비용 · 정확도 하락
검색해서 넣기 (RAG)	질문과 관련된 **부분만 찾아** 붙인다	긴 문서도 됨. 갱신은 파일 교체. 출처 표시	검색이 틀리면 답도 틀린다

2차시의 프로젝트 첨부는 어느 쪽인가

작은 자료는 **통째로 넣기**다. 자료가 커지면 서비스가 뒤에서 검색으로 바꾼다. 방금 실습 0에서 본 규정집(약 3,400자)은 통째로도 들어가지만, 규정집이 300쪽이면 검색이 필요하다.

◎ 오늘은 세 번째 길

모델은 그대로 두고, **찾아서 붙이는 부분**을 직접 만든다. 그래서 어디서 틀리는지도 직접 볼 수 있다.

RAG 한 줄 정의

RAG (Retrieval-Augmented Generation, 검색 증강 생성)

답하기 전에 관련 문서 조각을 **찾아서**(검색, Retrieval) 프롬프트에 **붙이고**(증강, Augmented) 그것을 근거로 **답하게**(생성, Generation) 하는 방법. 세 단어가 곧 순서다.

비유: 오픈북 시험

책을 통째로 외운 사람(파인튜닝)이 아니라, 색인으로 **해당 쪽을 펴서** 읽고 답하는 사람. 책이 바뀌면 새 책을 펴면 된다. 답 옆에 쪽수를 적을 수 있다.

바뀌는 것과 그대로인 것

모델은 **그대로**다. 바뀌는 것은 **프롬프트**뿐 — 질문 앞에 문서 조각이 붙는다. 1차시 5요소로 말하면 **맥락** 칸을 자동으로 채우는 장치다.

RAG가 해 주지 않는 것

문서에 없는 것을 알게 하지는 않는다. 문서가 틀리면 답도 틀린다. 검색이 엉뚱한 조각을 가져오면 답도 엉뚱하다. 그래서 오늘 "없으면 없다고 하기"와 "근거 조각 보여 주기"를 규칙으로 넣는다.

이미 쓰고 있는 RAG



2차시 프로젝트 자료

첨부가 작으면 통째로, 커지면 검색으로. 사용자는 차이를 못 느낀다



웹 검색 붙은 답변

검색 결과 몇 개가 "조각"이 되어 프롬프트에 붙는다. 출처 링크가 그 흔적



사내 문서 챗봇

규정 · 매뉴얼 · FAQ에 답하는 챗봇 대부분이 이 구조. 오늘 만드는 것

오늘은 그 속을 열어 본다

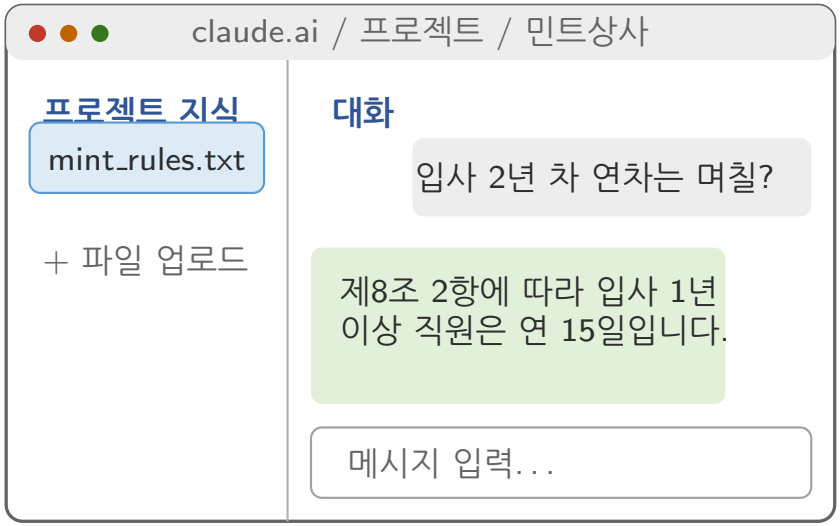
세 경우 모두 사용자에게는 "찾는 과정"이 보이지 않는다. 오늘은 자르기 · 숫자로 · 찾기 · 답하기 네 단계를 각자의 노트북에서 한 단계씩 돌려 보고, **어느 단계에서 틀리는지** 직접 확인한다. 이것이 서비스만 쓰는 사람과 만들 줄 아는 사람의 차이다.

먼저 서비스로 맛본다

다음 실습은 claude.ai 프로젝트에 규정집을 넣고 묻는 것이다. 잘 되는 모습을 먼저 보고, 2부부터 그 안을 만든다.

실습 1: claude.ai 프로젝트로 맛보기 (5분)

`prompts/01b_claude_project.txt` — 순서와 질문 3개



순서

1) 왼쪽 메뉴 **프로젝트** → 새 프로젝트
2) 이름 "민트상사" → 만들기
3) **프로젝트 지식**에 `mint_rules.txt` 업로드
4) 질문 **1번 · 3번 · 14번**을 차례로
5) 답마다 **조항 번호**가 붙는지 본다

관찰 포인트

3번(숙박비): 80,000원이라고 하는가, 부칙의 종전 값 70,000원을 섞는가. 14번(주차비): "규정집에 없다"고 하는가, 교통비 조항을 끌어와 지어내는가. 답이 어디서 왔는지는 **화면에 보이지 않는다** — 이 점을 기억해 둔다.

실습 1에서 본 것

잘한 것

✓ 조항 번호를 붙여 답했다
✓ 없는 질문에 대체로 "없다"고 했다
✓ 파일 하나 올리고 바로 물을 수 있었다

보이지 않는 것

✗ 어느 부분을 읽고 답했는지 **안 보인다**
✗ 문서가 수백 쪽이면 어떻게 되는지 모른다
✗ 우리 서버에서 돌릴 수 없다(외부 서비스)

이 상자를 열어 보는 것이 2부부터 4부까지

2부에서 네 단계를 그림으로 보고 노트북에서 숫자를 눈으로 확인한다. 3부에서 검색 결과를 직접 읽고, 찾은 조각을 claude.ai에 붙여 답을 받는다(손으로 하는 RAG). 4부에서 그 손작업을 코드가 대신하게 하고 질문을 받아 답하는 챗봇으로 묶는다. 틀리는 곳도 그때 찾는다.

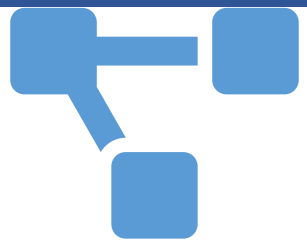
프로젝트는 그대로 둔다

3부 실습 4에서 claude.ai를 "답하는 쪽"으로 다시 쓴다. 그때는 프로젝트가 아니라 **새 대화**에서, 우리가 찾은 조각만 붙여 묻는다. 두 결과를 비교하게 된다.

왜 RAG인가

1. AI는 **대화창 안의 것만** 보고, 모르는 것도 유창하게 답한다(1차시). 그래서 우리 문서에 대한 질문에는 **일반론**이 나온다.
2. 문서를 알게 하는 길은 셋: 파인튜닝(다시 학습), 통째로 넣기(전체를 매번), **검색해서 넣기**(관련 부분만). 긴 문서 · 잦은 갱신 · 출처 표시에는 세 번째가 맞다.
3. RAG는 **찾아서 · 붙이고 · 답한다**. 모델은 그대로, 프롬프트의 맥락 칸만 자동으로 채운다.
4. 서비스(프로젝트)로는 잘 되지만 **어디서 찾았는지 보이지 않는다**. 2부부터 그 속을 직접 만든다.

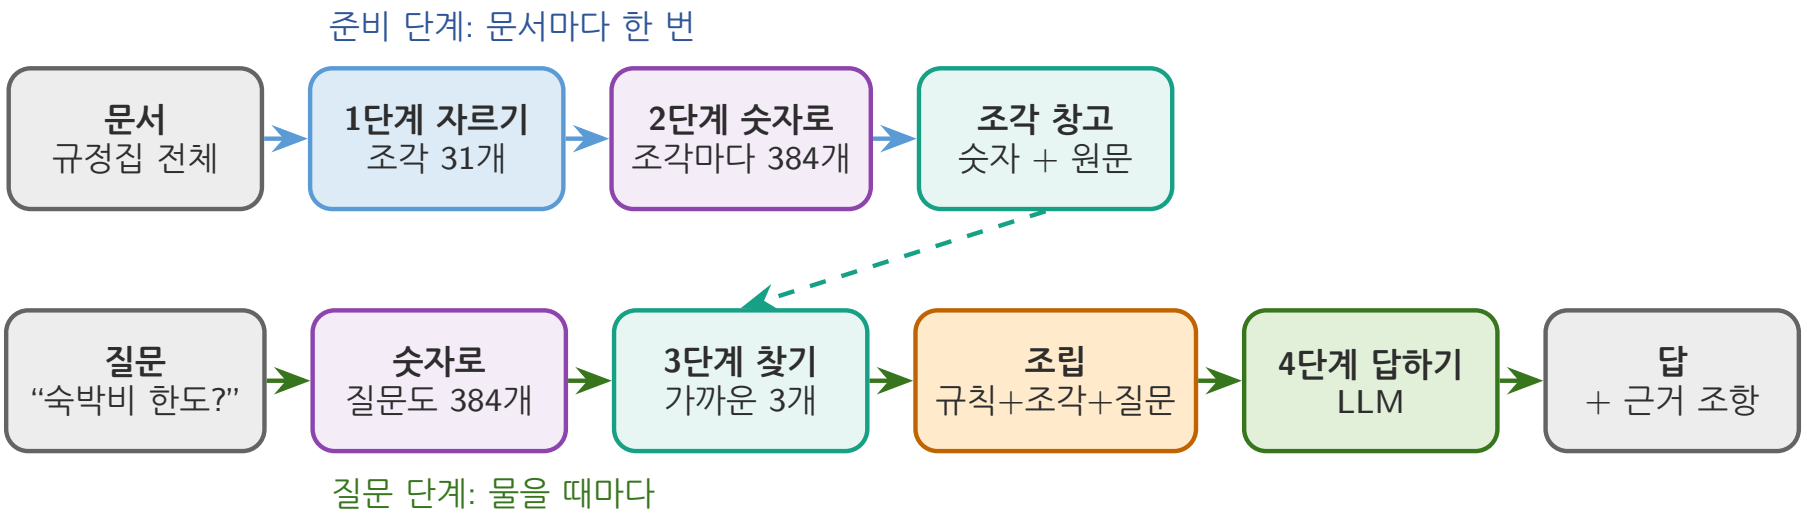
한 줄: RAG는 오픈북 시험이다 — 외우지 않고, 해당 쪽을 펴서 답한다.



2부 RAG 구조

자르기 · 숫자로 · 찾기 · 답하기

RAG 4단계 한눈에



두 줄로 읽는다

윗줄은 문서를 **조각 창고**에 넣는 준비, 아랫줄은 질문마다 **가까운 조각을 꺼내** 붙이고 답을 받는 일. 노트북 셀 1~4가 윗줄, 셀 5~8이 아랫줄.

실습 1에서 본 것과의 관계

claude.ai 프로젝트는 이 그림을 상자 안에 숨겨 두었다. 오늘은 상자를 열어 단계마다 결과를 눈으로 본다.

1단계 자르기(청킹)

✂ 왜 자르나

문서 전체를 한 덩어리로 두면 "숙박비" 질문에 문서 전체가 답으로 올라온다. 관련 없는 부분이 섞이면 답이 흐려지고 길어진다. 그래서 **질문 하나에 답할 만한 크기**로 미리 잘라 둔다.

조항 단위 (오늘 기본)

"제N조"가 나올 때마다 끊는다. 규정집·매뉴얼처럼 **번호가 있는 문서**에는 이것이 최선. 한 조각이 한 주제를 온전히 담는다. 결과: 조각 31개.

글자 수 단위 (실습 7)

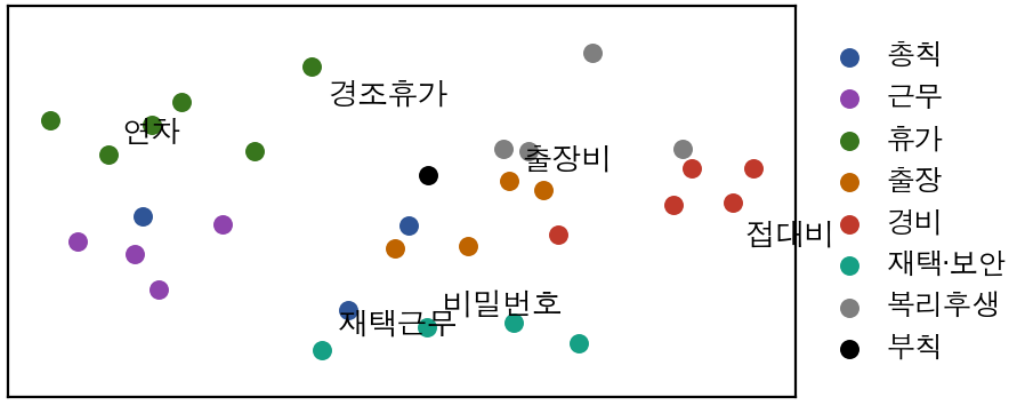
200자씩 기계적으로 끊는다. 번호가 없는 긴 글에 쓴다. 조항 한가운데가 잘릴 수 있어, 앞 조각의 끝을 다음 조각 앞에 **겹쳐** 넣어 완화한다.

조각 하나의 실제 모습 (제15조)

제15조(국내 출장비) 국내 출장비는 1일 기준 다음 한도 안에서 실비로 정산한다. 교통비: 실비. 숙박비: 1박 80,000원 한도. 식비: 1일 25,000원 한도. 일비: 1일 20,000원 정액. 숙박이 없는 당일 출장은 식비와 일비만 지급한다.

문장 하나가 숫자 384개로

임베딩 모델은 문장을 읽고 숫자 384개짜리 목록(벡터)을 내놓는다. **뜻이 비슷하면 숫자도 가깝다.** "숙박비 한도"와 "호텔 비용은 얼마까지"는 단어가 다르지만 숫자는 가깝다. 아래 그림에서 휴가 · 출장 · 경비 · 보안 조항이 각각 무리를 짓는다.



조항 31개의 벡터를 2차원으로 누른 그림 (가까울수록 뜻이 비슷)

오늘 쓰는 모델

`multilingual-e5-small`. 한국어를 포함한 다국어 지원, 무료 · 공개, 크기 약 470MB라 Colab 무료 CPU에서도 돈다. 셀 4가 자동으로 내려받는다.

얼마나 비슷한가: 유사도

코사인 유사도

두 벡터가 가리키는 **방향이 얼마나 같은가**를 0에서 1 사이 숫자로 잰다. 1에 가까울수록 뜻이 비슷하다. 질문 벡터와 조각 31개의 벡터를 하나씩 비교하면 점수 31개가 나온다.

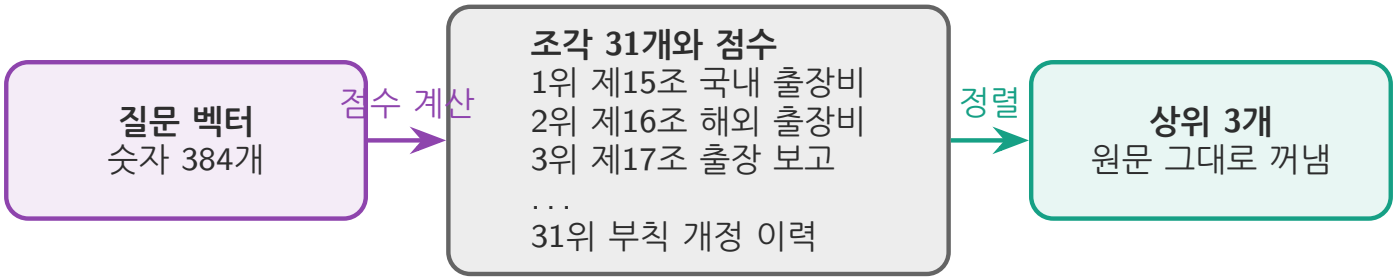
조각	내용	점수
제15조 국내 출장비	숙박비 1박 80,000원 한도, 식비 25,000원	0.89
제10조 경조휴가	본인 결혼 5일, 배우자 출산 10일 . . .	0.79
제25조 비밀번호	90일마다 변경, 10자 이상 . . .	0.76

질문: “국내 출장 숙박비 한도는 1박에 얼마인가요?” 점수는 노트북 셀 4의 실행 결과.

단어가 안 겹쳐도 점수가 높다

질문에는 “호텔”도 “숙소”도 없지만 제15조가 1위다. 반대로 “비밀번호” 조항은 글자 수가 비슷해도 점수가 낮다. 검색이 **글자 맞추기가 아니라 뜻 맞추기**라는 뜻이다.

3단계 찾기(검색)



상위 몇 개를 꺼내나

오늘은 **3개**(k). 적으면 답에 필요한 조각을 놓치고, 많으면 관련 없는 조각이 섞인다. 점수가 일정 값보다 낮으면 "관련 조각 없음"으로 처리하는 **임계값**을 둘 수도 있다(실습 7).

검색은 항상 무엇인가를 돌려준다

"주차비 지원되나요?"처럼 규정집에 없는 질문에도 **가장 덜 먼 조각 3개**가 올라온다. 검색만으로는 "없다"를 알 수 없다. 그래서 4단계의 규칙이 필요하다.

4단계 답하기: 프롬프트 조립

>_ 조립된 프롬프트의 골격 (셀 6이 만든다)

```
[규칙] 아래 규정집 조각만 근거로 답한다.
  조각에 없으면 "규정집에 없습니다"라고만 답한다.
  근거 조항 번호를 쓴다. 3문장 이내로 답한다.
[규정집 조각]
(1) 제15조(국내 출장비) ... 숙박비: 1박 80,000원 한도 ...
(2) 제16조(해외 출장비) 항공권은 이코노미석을 원칙으로 ...
(3) 제17조(출장 보고) 출장에서 복귀한 뒤 5근무일 이내에 ...
[질문] 국내 출장 숙박비 한도는 1박에 얼마인가요?
```

1차시 5요소로 보면

규칙 4줄은 제약과 형식, **조각**은 맥락, **질문**은 과제다. 역할은 생략해도 된다. RAG가 하는 일은 결국 **맥락 칸을 자동으로 채우는 것**이고, 나머지는 1차시에서 배운 프롬프트 그대로다.

노트북 사용 규칙 3가지

1. 위에서 아래로

셀은 순서대로 누른다. 건너뛰면 뒤 셀이 앞 셀의 결과를 못 찾는다

2. 끝난 뒤 다음 셀

셀 왼쪽 괄호 안 숫자가 바뀌면 끝난 것. 빙글 도는 동안은 기다린다

3. 표시된 줄만 바꾼다

`# <-- 바꿔 보세요`가 붙은 줄만 고친다. 따옴표는 지우지 않는다

오늘 누를 셀은 9개

실습 2는 셀 1~4(준비 · 문서 · 자르기 · 숫자로), 실습 3은 셀 5(찾기), 실습 4는 셀 6(조립). 4부에서 셀 7(답하기) · 셀 8(챗봇) · 셀 9(내 문서). 셀마다 맨 위 주석에 번호와 할 일이 적혀 있다.

빨간 글씨가 나오면

에러는 지우지 말고 그대로 둔 채 손을 든다. 대부분은 **셀 1을 안 돌렸거나** 순서를 건너뛴 경우다. 셀 1부터 다시 누르면 대개 해결된다(안 될 때 표는 3부 끝).

실습 2: 자르기 · 숫자로 · 유사도 (8분)

prompts/02_cells_1_to_4.txt — 셀별 기대 출력과 체크

▶ 셀 1부터 4까지 차례로 ▶ — 이렇게 나오면 정상

셀 1 준비 → 마지막 줄에 준비 완료
셀 2 문서 → 글자 수: 3,084자 / 조항 수: 30개 (규정집은 노트북에 내장, 업로드 없음)
셀 3 자르기 → 조각 수: 31개와 첫 조각 [1] [제1장 총칙] 제1조(목적) ...
셀 4 숫자로 → (31, 384), 앞 5개 숫자, 그리고 문장 3개의 유사도 표

셀 4는 기다린다

임베딩 모델을 처음 내려받는 데 1~2분. 진행 막대가 여러 개 지나간다. 두 번째부터는 바로 끝난다.

체크

✓ 셀 3의 조각 수가 31개다
✓ 셀 4의 모양이 (31, 384)다
✓ 유사도 표에서 뜻이 비슷한 쌍의 점수가 가장 높다

숫자 5개를 보고 "이게 뜻이라고?"라는 의문이 정상이다. 사람은 못 읽지만 컴퓨터는 이 숫자로 거리를 잰다.

2부 요약: RAG 구조

네 단계, 두 줄

1. **자르기**: 질문 하나에 답할 크기로. 번호 있는 문서는 조항 단위가 최선.
2. **숫자로**: 문장 하나가 숫자 384개. 뜻이 비슷하면 숫자가 가깝다. 질문도 같은 방법으로.
3. **찾기**: 질문 벡터와 조각 벡터의 유사도로 상위 3개. 검색은 없는 질문에도 무엇인가를 돌려준다.
4. **답하기**: 규칙 + 조각 + 질문을 조립한 프롬프트를 LLM에 준다. 1차시 5요소의 맥락 칸이 자동으로 채워진 것.

한 줄: RAG는 새 모델이 아니라, 답하기 전에 **찾아서 붙이는 절차**다.



3부 직접 조립

찾고, 붙이고, 물어보기

실습 3: 검색해 보기 (6분)

prompts/03_search.txt — 질문 순서와 관찰 포인트

셀 5에서 이 줄만 바꾼다

`QUESTION = "입사 2년 차 직원의 연차는 며칠인가요?" # <-- 바꿔 보세요` → 따옴표 안만 바꾸고 ▶. 질문 세트의 **1번 → 3번 → 5번 → 11번** 순서로 네 번 실행한다.

이런 형태로 나온다 (3번 질문)

```
1위  점수 0.89  제15조(국내 출장비)
2위  점수 0.84  제16조(해외 출장비)
3위  점수 0.83  제17조(출장 보고)
```

체크

✓ 1번 질문: 1위가 제8조(연차휴가)인가
✓ 3번: 1위 제15조 0.89. 부칙(종전 값 70,000원)은 31위라 안 올라온다
✓ 5번: 정답 제19조가 **5위** — 상위 3 밖. 첫 "검색 실패" 사례
✓ 11번 "애 낳으면 며칠 쉬어요?": "출산"이라는 단어 없이도 제10조(경조휴가)가 올라오는가

검색 결과 읽기: 점수와 순위

셀 5의 출력에서 볼 것은 두 가지다. **1위가 맞는 조항인가**, 그리고 **1위와 2위의 점수 차이**.

잘 찾은 경우

- 1위 점수가 2위보다 확실히 높다
- 1위 조항의 제목이 질문의 주제와 맞다
- 상위 3개가 같은 장(예: 4장 출장) 안에 있다

의심할 경우

- 1 · 2 · 3위 점수가 거의 같다
- 엉뚱한 장의 조항이 1위다
- 규정집에 없는 질문인데 점수가 높다

점수는 상대 비교용

0.8이 "정답"이고 0.6이 "오답"인 것이 아니다. 같은 모델, 같은 문서 안에서 **서로 견줄 때만** 의미가 있다. 모델이나 문서를 바꾸면 점수대가 통째로 달라진다.

의심되면 질문을 문서의 말로 바꿔 본다

"애 낳으면" 대신 "배우자 출산"으로 물어 점수가 크게 오르면, 표현 차이가 원인이다. 이것이 실습 7의 실험 중 하나다.

실습 4: 수동 RAG — 붙여넣기로 완성 (12분)

`prompts/04_manual_rag.txt` — 순서와 규칙 4줄 원문

1. 셀 6 실행
질문은 3번(숙박비). 셀 5의 QUESTION을 그대로 쓴다

2. 출력 전부 복사
[규칙]부터 [질문]까지 드래그, Ctrl+C

3. 붙여넣기
새 대화를 열고 Ctrl+V, Enter. 프로젝트 밖의 일반 대화

4. 답 확인
제15조 · 80,000원이 있나, 조각에 없는 말을 보탰나

↻ 이어서 14번 "주차비는 지원되나요?"로 한 번 더

셀 5의 QUESTION을 14번으로 바꾸고 셀 5 → 셀 6 → 복사 → 붙여넣기. 기대하는 답은 **"규정집에 없습니다"** 한 줄. 교통비 조항을 끌어와 "실비 지원"이라고 지어내면 실패다.

⇄ 지금 손으로 한 일

셀 6이 만든 글을 복사해 LLM에 넣고 답을 받았다. 4부에서는 이 복사 · 붙여넣기를 **코드 한 줄**이 대신한다. 그것이 "자동 RAG"의 전부다.

조립 프롬프트 해부

>_ 셀 6의 실제 출력 (3번 질문, 조각 2개만 표시)

```
[규칙] 아래 규정집 조각만 근거로 답한다.
  조각에 없으면 "규정집에 없습니다"라고만 답한다.
  근거 조항 번호를 쓴다. 3문장 이내로 답한다.
[규정집 조각]
(1) 제15조(국내 출장비) ... 숙박비: 1박 80,000원 한도 ...
(2) 제16조(해외 출장비) 항공권은 이코노미석을 원칙으로 ...
[질문] 국내 출장 숙박비 한도는 1박에 얼마인가요?
```

규칙	막는 실패
조각만 근거로 답한다	모델이 알던 일반론(법정 기준 등)을 우리 규정인 양 답함
없으면 “규정집에 없습니다”	없는 질문에 비슷한 조항을 끌어와 지어냄
근거 조항 번호를 쓴다	출처 없는 답. 사람이 확인할 길이 없어짐
3문장 이내	장황한 답. 숫자 하나 찾는데 열 줄

같은 질문, 다른 결과

질문은 같다: “국내 출장 숙박비 한도는 1박에 얼마인가요?”

그냥 물었을 때

“회사마다 다르지만 보통 5만~10만 원 수준이며 . . . 인사팀에 확인하세요.” 일반론이고, 우리 규정이 아니며, 출처가 없다. 틀린 말은 아니라서 더 위험하다.

조립해서 물었을 때

“1박 80,000원 한도입니다(제15조). 숙박이 없는 당일 출장은 식비와 일비만 지급됩니다.” 값과 조항을 댔고, 조각 밖의 말을 보태지 않았다.

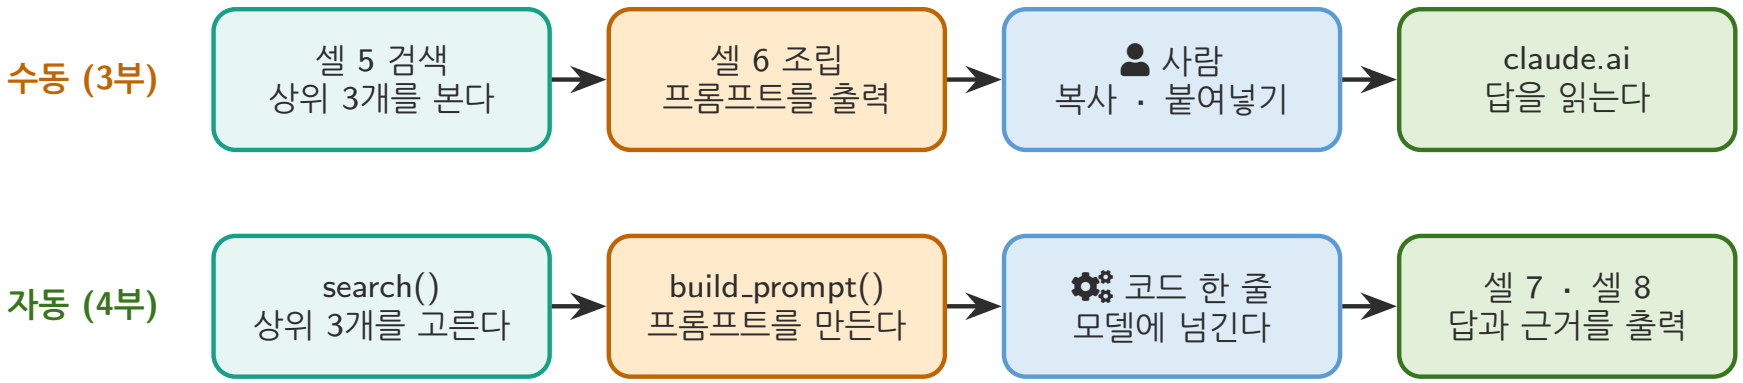
달라진 것은 모델이 아니다

두 답 모두 같은 claude.ai가 냈다. 달라진 것은 **프롬프트에 붙은 조각 3개와 규칙 4줄**뿐이다. 모델을 바꾸지 않고 결과를 바꾸는 것, 이것이 1차시부터 이어진 원칙이다.

직접 비교해 본다

실습 4에서 조립 프롬프트를 넣기 전에, 같은 대화창에 질문만 먼저 넣어 보면 두 답을 나란히 볼 수 있다.

이것이 RAG의 전부다



자동화해도 원리는 같다

위아래 줄의 칸은 하나씩 대응한다. 사람이 하던 복사 · 붙여넣기 자리에 코드 한 줄이 들어갔을 뿐이다. 그래서 챗봇이 틀리면 **어느 칸에서 틀렸는지** 위 줄로 돌아가 하나씩 확인할 수 있다(4부).

그래서 3부를 손으로 했다

한 번이라도 손으로 조립해 본 사람은 챗봇의 답을 "마법"이 아니라 **프롬프트의 결과**로 본다. 근거 조각이 이상하면 검색을, 조각은 맞는데 답이 이상하면 규칙을 의심한다.

안 될 때: 증상별 조치

prompts/09_stuck.txt — 표 전문

화면에 뜬 말	원인	조치
`ModuleNotFoundError`	셀 1을 안 돌림	셀 1을 ▶, 끝나면 하던 셀을 다시 ▶
"런타임 연결이 해제되었습니다"	오래 쉬어 세션 종료	런타임 → 다시 연결, 그 뒤 셀 1부터 순서대로
`NameError: name 'search'`	셀 4·5를 건너뜀	셀 4 → 셀 5 순서로 다시 ▶
아무 출력도 안 보임	실행 중 또는 클릭 실패	셀 왼쪽 숫자가 바뀌었는지 확인. 빙글 돌면 기다린다
claude.ai "사용 한도에 도달"	무료 한도 소진	옆 사람 계정으로 붙여넣기, 또는 표시된 시간 뒤에

5분 규칙

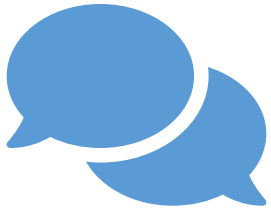
표에 없는 에러는 빨간 글씨 **마지막 줄**을 그대로 두고 손을 든다. 조교가 화면을 보는 것이 가장 빠르다. 에러를 한국어로 요약해 말하지 않는다.

3부 요약: 직접 조립

찾고, 붙이고, 물어봤다

1. **검색 결과는 읽는 것**이다. 1위가 맞는 조항인지, 1위와 2위의 점수 차이가 있는지 본다.
2. **조립 프롬프트** = 규칙 4줄 + 조각 3개 + 질문. 규칙 하나가 실패 하나를 막는다.
3. 같은 모델, 같은 질문이라도 **조각이 붙으면 답이 달라진다**. 값 · 조항 · 개정 이력까지.
4. 손으로 한 복사 · 붙여넣기가 자동 RAG의 전부다. 틀리면 검색인지 규칙인지 나눠 본다.

한 줄: 챗봇의 답은 마법이 아니라 **프롬프트의 결과**다.



4부 챗봇 완성

자동으로 답하고, 틀리는 곳을 찾는다

생성 모델을 노트북 안에

답하기 단계를 노트북으로 옮긴다

지금까지 "답하기"는 claude.ai가 했다(실습 4의 붙여넣기). 셀 7은 작은 공개 모델 **Qwen2.5-1.5B-Instruct**(약 3GB)를 노트북 안에 내려받아 **같은 프롬프트**로 같은 일을 시킨다. 조립 방식은 3부와 한 글자도 다르지 않다.

GPU가 잡혔으면

첫 실행 때 모델 내려받기 1~2분. 그 뒤 질문 하나에 답 **5~10초**. 셀 7 맨 위에 "GPU 사용"이 찍힌다.

GPU가 없으면

셀 7은 안내문만 출력하고 넘어간다. 셀 8의 챗봇은 **그래도 동작**한다: 근거 조각과 붙여넣기용 프롬프트를 돌려주므로 실습 4 방식으로 이어 간다.

작은 모델의 한계

1.5B는 claude.ai보다 **훨씬 작아** 더 자주 틀린다. 그래서 규칙 4줄과 **근거 조각 표시**가 더 중요하다. 틀렸을 때 어느 단계가 틀렸는지 사람이 볼 수 있어야 한다.

실습 5: 자동으로 답하기 (6분)

prompts/05_auto_answer.txt

순서

1) 셀 7 실행 → 첫 줄이 "GPU 사용"인지 확인(아니면 아래 상자로) **2)** 셀 7의 질문 줄("바꿔 보세요" 표시)을 **3번**으로 바꾸고 다시 실행 **3)** 같은 방법으로 **7번**, **14번**

기대 출력 형태 (3번 질문)

```
질문: 국내 출장 숙박비 한도는 1박에 얼마인가요?
답: 숙박비의 한도는 1박 80,000원입니다.
근거 조각: 제15조, 제16조, 제17조
```

체크

✓ **근거 조각** 줄에 정답 조항이 있는가(답엔 번호가 빠지기도 한다)
✓ 3번: 80,000원 (다른 숫자를 섞으면 X)
✓ 7번: 제27조로 "지금"이라 하는가
✓ 14번: "**규정집에 없습니다**"인가

GPU가 없는 사람

셀 7을 건너뛰고 실습 4의 결과(claude.ai 답)를 같은 체크표로 본다. 옆 사람이 GPU가 잡혔으면 화면을 같이 본다. 실습 6부터는 모두 같이 한다.

챗봇 만들기: 질문 받고 답하기를 되풀이

```
# 셀 8. 챗봇 — 질문을 받아 답하기를 되풀이합니다 (GPU가 없어도 동작)
while True:
    question = input("질문> ").strip() …
```

```
민트상사 규정집 챗봇입니다. 질문을 쓰고 Enter. 끝내려면 빈 칸에서 Enter.

질문>  국내 출장 숙박비 한도는 1박에 얼마인가요?
답: 숙박비의 한도는 1박 80,000원입니다.
[찾은 조각]
  1위  점수 0.89  제15조(국내 출장비)
  2위  점수 0.84  제16조(해외 출장비)
  3위  점수 0.83  제17조(출장 보고)

질문>  주차비는 지원되나요?
답: 규정집에 없습니다.
[찾은 조각]
  1위  점수 0.83  제27조(중식 지원)
  2위  점수 0.83  제28조(자기계발비)
  3위  점수 0.82  제21조(접대비)
질문>
```

셀 8: 입력 칸 하나가 챗봇이다

셀 8을 실행하면 출력 맨 아래에 질문> 입력 칸이 생긴다. 질문을 쓰고 Enter를 누르면 **답**과 그 아래 **찾은 조각**(조항 번호 · 점수)이 나오고, 입력 칸이 다시 생긴다. 우리가 만든 찾기 · 조립 · 답하기를 질문마다 되풀이해 부를 뿐, 새로운 것은 없다.

끝내기 · 안 될 때

끝내려면 빈 칸에서 Enter, 또는 셀 왼쪽의 ■. 입력 칸이 안 보이면 출력 맨 아래로 내려 본다. 그래도 없으면 셀 8을 다시 실행한다. 별도 화면이나 링크는 없다.

실습 6: 챗봇 사용 (6분)

prompts/06_chatbot_questions.txt — 체크표 전문

순서

1) 셀 8 실행 → 질문> 칸 **2)** 아래 질문 5개를 차례로 입력 **3)** 답마다 세 칸에 O · X **4)** 옆 사람과 질문 1개씩 새로 만들어 서로의 챗봇에 넣어 본다

질문	답 맞음	조항 인용	없다고 답함
1. 입사 2년 차 직원의 연차는 며칠인가요?	☐	☐	—
5. 15만 원짜리 물품을 회사 경비로 사려면?	☐	☐	—
9. 올해 못 쓴 연차는 어떻게 되나요?	☐	☐	—
12. 회식비는 1인당 얼마까지 되나요?	☐	☐	☐
15. 육아휴직은 몇 년까지 쓸 수 있나요?	—	—	☐

12번이 가장 어렵다

규정집에 "회식비"는 없고 "접대비"(제21조)만 있다. 접대비 5만 원을 회식비라고 답하면 X. "회식비 항목은 없고 접대비는 1인 50,000원"이면 O.

실습 7: 일부러 틀리게 만들기 (8분)

`prompts/07_break_it.txt` — 기록표 전문

1. 자르기 방식 바꾸기

셀 3의 조각 방식을 "조항"에서 "글자수"로. 셀 3 · 4 · 5를 순서대로 다시 실행하고 3번 질문 결과를 비교

2. 질문 표현 바꾸기

11번 "애 낳으면 며칠 쉬어요?", 13번 "오후에 반나절만". 규정집 단어와 다른 말로 물어도 찾는가

3. 없는 질문 넣기

14∼16번 (주차비 · 육아휴직 · 퇴직금). 검색은 뭔가를 올리지만 답은 "없습니다"여야 한다

무엇을 바꿨나	검색 결과가 바뀌었나	답이 바뀌었나
자르기: 조항 → 글자수	올라온 조각 · 점수	값 · 근거 조항
질문 표현 (11 · 13번)	제10조 · 제9조가 올라오나	맞는 조항을 인용하나
없는 질문 (14∼16번)	무엇이 올라오나 · 점수	"없습니다"인가 지어냈나

되돌리기

실험이 끝나면 셀 3을 "조항"으로 되돌리고 셀 3 · 4 · 5를 다시 실행한다. 순서를 건너뛰면 `NameError`가 난다.

왜 틀리나: 검색 실패와 생성 실패

증상	어느 단계	처방
올라온 조각이 엉뚱하다 (제25조 비밀번호가 1위)	**검색 실패**	자르기를 조항 단위로 되돌리기 · 상위 k 늘리기 · 질문을 규정집 단어로 바꿔 보기
조각은 맞는데 답이 틀리다 (제15조를 보고 70,000원)	**생성 실패**	규칙 추가 "개정 이력이 있으면 최신 값" · 같은 프롬프트를 더 큰 모델(claude.ai)에
없는 질문에 답을 지어낸다 (주차비 "실비 지원")	**규칙 부족**	"없으면 없다고만" 규칙 확인 · 1위 점수가 낮으면 답하지 않는 임계값

근거 조각을 항상 같이 출력하는 이유

답만 보면 어디서 틀렸는지 모른다. 조각이 같이 나오면 **조각이 엉뚱한지**(검색) **조각은 맞는데 잘못 읽었는지**(생성)를 사람이 바로 가른다. 고칠 곳이 달라진다.

실습 7 기록표와 대응

"검색 결과가 바뀌었나" 열이 검색 단계, "답이 바뀌었나" 열이 생성 단계다. 두 열을 나눠 적는 이유가 이 표다.

실습 8 (선택): 내 문서로 바꾸기

prompts/08_my_document.txt

1. 파일 준비
txt 또는 pdf 하나. 공개 자료나 직접 쓴 비업무 문서

2. 셀 9 업로드
셀 9 실행 → "파일 선택" 단추 → 파일 고르기

3. 셀 3 · 4 재실행
새 문서를 자르고 숫자로. 조각 수가 바뀐 것을 확인

4. 질문
셀 8 챗봇에 내 문서 질문 3개. 없는 질문 1개도 넣는다

공개 문서 · 가상 문서만 (1 · 2차시 원칙)

예: 공개된 제품 설명서, 도서관 이용 안내, 직접 쓴 동호회 규칙, 공공기관이 배포한 안내문.
업무 문서 · 개인정보가 든 문서는 올리지 않는다. Colab은 외부 서버다.

pdf는 글자가 복사되는 파일만

스캔한 이미지 pdf는 글자를 못 읽는다(조각 0개). pdf를 열어 글자를 드래그해 복사되면 된다.
표가 많은 문서는 조각이 어지러워지므로 첫 실험은 글 위주 문서로.

더 좋아지게 하는 방법 (오늘은 이름만)

방법	무엇을 고치나	어느 실패에
청크 겹침	조각 경계에 걸린 문장이 잘리지 않게 앞뒤를 조금씩 겹쳐 자른다	검색
상위 k · 점수 임계값	몇 개를 붙일지, 점수가 얼마 아래면 "관련 없음"으로 볼지 정한다	검색 · 규칙
키워드 검색 병행	의미 검색이 놓치는 고유명사·숫자·조항 번호를 단어 일치로 보완한다	검색
재정렬(리랭킹)	상위 후보를 다른 모델로 한 번 더 채점해 순서를 바로잡는다	검색
답 평가 세트	질문·정답 묶음을 두고 고칠 때마다 정답률을 다시 잰다	전부

순서는 항상 같다

틀린 질문을 **모으고** → 검색 실패인지 생성 실패인지 **나누고** → **그쪽만** 고친다. 방법 이름보다 이 순서가 중요하다. 오늘 노트북의 상위 k와 자르기 방식이 그 첫 손잡이다.

4부 요약

1. **답하기를 노트북 안으로**: 작은 공개 모델이 3부와 같은 프롬프트로 답한다. GPU가 없으면 claude.ai 붙여넣기로 대신한다 — 원리는 같다
2. **챗봇은 포장**: 셀 8은 찾기 · 조립 · 답하기를 질문마다 되풀이해 부를 뿐. 답과 찾은 조각을 항상 같이 보여 준다
3. **일부러 틀리게 해 본다**: 자르기 방식, 질문 표현, 없는 질문. 무엇을 바꿨을 때 검색이 바뀌는지 답이 바뀌는지 따로 적는다
4. **틀리면 단계를 가른다**: 조각이 엉뚱하면 검색, 조각은 맞는데 답이 틀리면 생성, 없는 질문에 답하면 규칙

한 문장으로

챗봇의 품질은 모델이 아니라 **찾아온 조각**과 **규칙**이 정한다. 그래서 근거를 보여 주는 챗봇만 고칠 수 있다.



5부 운영과 보안

어떤 문서를, 어디에 두는가

올려도 되는 문서, 안 되는 문서

되는 것

- 공개된 자료: 제품 설명서, 공공기관 안내문, 공개 보고서
- 가상 데이터: 오늘의 민트상사 규정집처럼 지어낸 것
- 내가 만든 비업무 문서: 동호회 규칙, 독서 메모

안 되는 것

- 실제 업무 문서, 내부 규정 · 매뉴얼 원본
- 개인정보가 든 파일: 명단, 연락처, 인사 자료
- 대외비 이상 — 규정집 제24조가 말하는 바로 그것

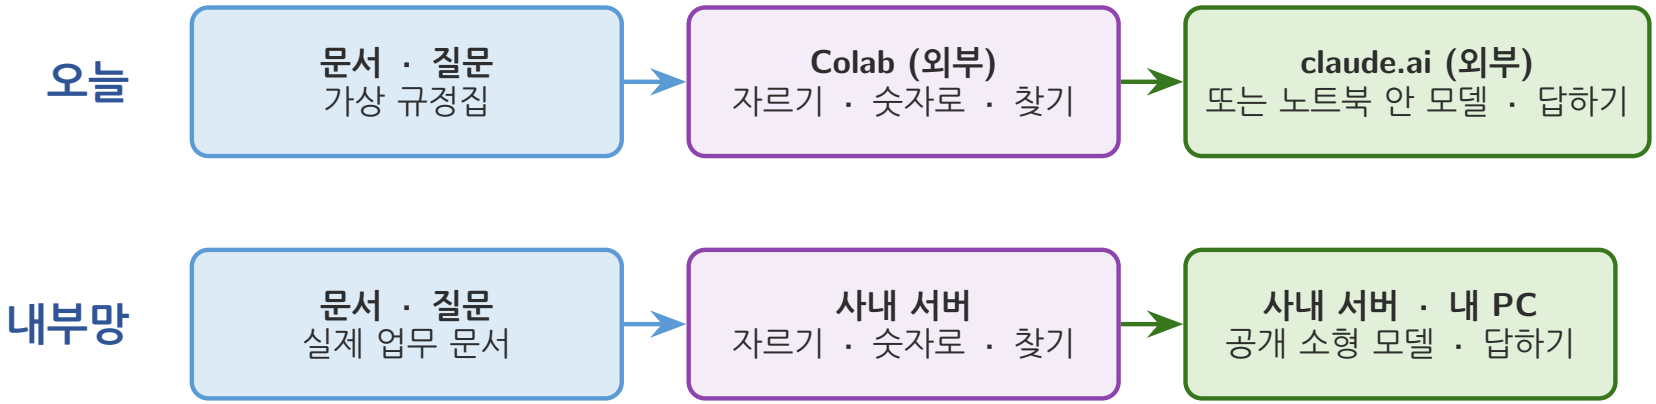
Colab도 claude.ai도 외부 서버다

붙여 넣은 문서, 올린 파일, 챗봇에 넣은 질문은 모두 회사 밖 서버로 간다. 1차시 보안 가이드라인(국가정보원, 2023.6)의 원칙 그대로: **비공개 자료는 외부 AI에 입력하지 않는다**.

망설여지면

"이 문서가 인터넷에 공개돼도 괜찮은가"를 묻는다. 아니오면 올리지 않는다. 실습은 가상 문서로 충분하다.

내부에서 돌리려면: 같은 4단계, 자리만 바꾼다



⇄ 오늘 노트북은 설계도다

임베딩 모델(e5-small)과 생성 모델(Qwen2.5)은 둘 다 공개 모델이라 인터넷이 끊긴 서버에도 내려받아 둘 수 있다. 바뀌는 것은 **모델이 놓인 자리**뿐이고, 자르기 · 숫자로 · 찾기 · 답하기 네 단계와 규칙 4줄은 그대로다. 6부에서 답하기를 실제로 **내 PC**로 옮겨 본다.

⚙ 내부에 둘 때 달라지는 일

문서 갱신(규정이 바뀌면 그 조각만 다시 숫자로), 접근 권한(누가 어떤 문서를 물을 수 있나), 서버 사양(생성 모델 크기에 따라 GPU). 오늘 범위 밖이지만 구조는 같다.

챗봇을 평가하는 법

묶음	질문 번호	재는 것
답이 문서에 있음	1~10번	값이 맞는가, 근거 조항을 댔는가, 예외를 빠뜨리지 않았는가
표현이 문서와 다름	11~13번	다른 말로 물어도 같은 조항을 찾는가
문서에 없음	14~16번	"규정집에 없습니다"라고 하는가, 비슷한 조항을 끌어다 지어내지 않는가

정답률
1~13번 중 값과 근거가 모두 맞은 수 ÷ 13

없음 처리율
14~16번 중 "없습니다"라고 답한 수 ÷ 3

두 숫자가 모두 높아야 한다

정답률만 높은 챗봇은 없는 것도 지어낸다. 없음 처리율만 높은 챗봇은 아는 것도 "없다"고 한다. 규칙을 고칠 때마다 두 숫자를 같이 다시 잰다. 질문 세트는 `docs/questions.txt`.

저장과 이관

1) Colab은 Drive에 **자동 저장**된다(제목 옆 "저장됨")
2) 파일 → 다운로드 → `.ipynb` 다운로드
3) 내려받은 파일을 조교에게 제출(수합 절차)
4) 실습 8을 했으면 올린 문서는 세션이 끝나면 지워진다 — 노트북에는 남지 않는다

나가기 전 (공용 PC)

✓ Google 계정 로그아웃(오른쪽 위 프로필)
✓ claude.ai 로그아웃
✓ 브라우저의 "비밀번호 저장" 제안은 거절했는지
✓ 다운로드 폴더의 `.ipynb` · 문서 파일 삭제
✓ Gmail 주소와 비밀번호는 휴대폰에 메모
✓ Ollama 앱 종료(작업 표시줄 오른쪽 라마 아이콘 → Quit)

집에서 이어서

같은 Google 계정으로 `colab.research.google.com`에 들어가 **Drive**에서 오늘 사본을 열면 그대로 이어진다. 런타임은 새로 시작되므로 셀 1부터 다시 실행한다.



6부 내 PC에서 답하기

생성기를 Colab에서 내 PC로: Ollama

왜 내 PC인가: 답하기 상자만 옮긴다

claude.ai (외부)
실습 4. 품질 가장 높음. 붙여 넣은 조각이 회사 밖 서버로 간다

Colab 안 Qwen (외부)
실습 5. 공개 소형 모델. 서버는 여전히 Google 것

내 PC의 Ollama
실습 9. 실습 0-3에서 설치한 앱. 프롬프트가 **PC 밖으로 안 나간다**

⇄ 5부 그림의 "사내 서버" 자리에 오늘은 내 PC를 놓는다

자르기 · 숫자로 · 찾기는 아직 Colab이 한다. **답하기**만 내 PC로 옮긴다. 프롬프트는 실습 4와 한 글자도 다르지 않다. 실습 0-4에서 받아 둔 모델이 준비돼 있는지 앱을 연다.

Ollama란

공개 모델을 내려받아 내 PC에서 돌리는 무료 프로그램(Windows · Mac). 채팅창이 있는 **앱**과, 글자로 치는 **명령어** 두 가지로 쓴다. 인터넷은 모델을 내려받을 때만 필요하다.

명령어로 쓰기: 여섯 개면 된다

>_ 명령 프롬프트 여는 법

시작 → `cmd` 입력 → Enter. 검은 창에 `C:\Users\이름>`가 보이면 그 뒤에 아래 명령을 치고 Enter.

명령	하는 일
`ollama list`	내려받은 모델 목록
`ollama pull qwen2.5:1.5b`	모델 내려받기(앱에서 골라도 같다)
`ollama run qwen2.5:1.5b`	대화 시작. >>> 뒤에 질문을 치고 Enter
`/bye`	대화 끝내기
`ollama ps`	지금 메모리에 올라온 모델
`ollama rm qwen2.5:1.5b`	모델 지우기(1GB 되찾기)

앱과 명령어는 같은 모델을 쓴다

앱에서 받은 모델이 `ollama list`에 보이고, 명령어로 받은 모델이 앱 목록에 보인다. 짧은 질문은 명령창, 긴 프롬프트 붙여넣기는 앱이 편하다.

명령창 화면: 문서 없이 물으면 지어낸다

명령 프롬프트 - ollama run qwen2.5:1.5b

```
C:\Users\mint>ollama list
NAME              ID              SIZE      MODIFIED
qwen2.5:1.5b      65ec06548149    986 MB    2 minutes ago

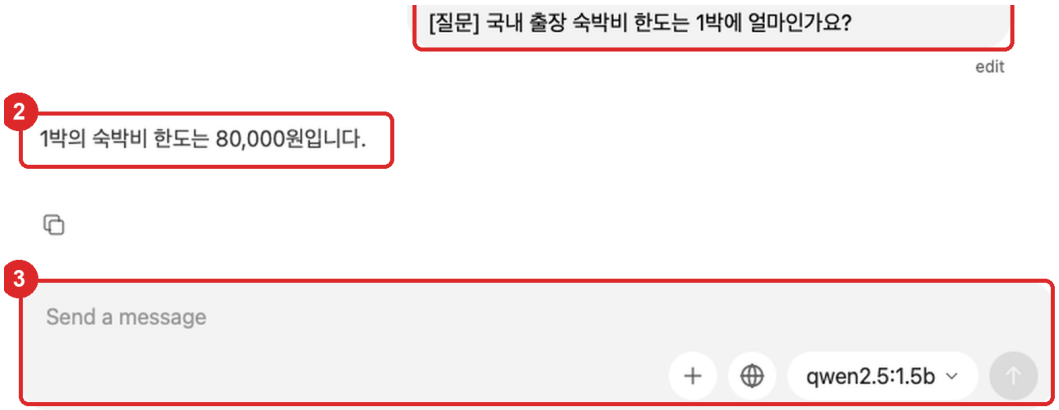
C:\Users\mint>ollama run qwen2.5:1.5b
>>> 국내 출장 숙박비 한도는 1박에 얼마인가요?
국내에서의 출장 숙박비 한도는 상황과 일정에 따라 다르므로 정확한 정보는 각 기업이나 관공서에 직접 문의하시는 것이
좋습니다. 일반적으로는 1박당 소득세가 부과되는 수준에서 결정됩니다. 하지만 일반적인 한도가 500만 원 정도라고 합
니다.

>>> /bye
C:\Users\mint>_
```

⚠ 위 화면의 교훈

문서 없이 물었더니 "일반적인 한도가 500만 원"이라고 **지어냈다**. 모델이 규정집을 모르기 때문이다. 실습 4에서 claude.ai가 일반론을 답한 것과 같은 현상. 실습 9에서 조각과 규칙을 붙여 준다.

실습 9: 내 PC에서 RAG 답 받기 (5분)



순서 (실습 4와 같은 프롬프트 · 전문은 prompts/10)

1) Colab 셀 6 출력([규칙]부터 [질문]까지)을 전부 복사 → Ollama 앱 입력창(빨간 3)에 붙여넣기 → Enter

2) 빨간 1이 붙여 넣은 프롬프트의 끝, 빨간 2가 답. **80,000원**인지 본다

3) 셀 5의 질문을 "주차비는 지원되나요?"로 바꿔 셀 5 · 6 실행 → 다시 붙여넣기 → "규정집에 없습니다"

체크표: 같은 프롬프트, 세 생성기

3번(80,000원 · 제15조)과 14번("없습니다")을 **claude.ai** · **Colab Qwen** · **내 PC Ollama** 세 칸에 O · X. 셋이 같으면 "답하기 상자는 옮길 수 있다"를 확인한 것.

무엇이 달라졌나 · 한계

	claude.ai	Colab 안 Qwen	내 PC Ollama
자료가 가는 곳	회사 밖 서버	Google 서버	**내 PC 안**
답 품질	높음	낮음(1.5B)	낮음(같은 1.5B)
비용 · 한도	무료 한도 있음	무료, GPU 보장 없음	무료, 한도 없음
속도	수 초	GPU 5∼10초	CPU 10∼30초
설치	없음	없음	설치 파일 + 모델 1GB

⚠ 작은 모델은 더 자주 틀린다

실측: 같은 모델이 "입사 2년 차 연차"를 25일이라고 답했다(정답 15일). 조각은 맞고 답이 틀린 **생성 실패**다. 규칙 4줄과 근거 조각 표시가 그래서 더 중요하다. 8GB PC는 1.5∼3B가 한계.

집에서 한 걸음 더

앱에 `mint_rules.txt`를 끌어다 놓고 물으면 "통째로 넣기"(1부의 두 번째 길)가 된다. 자르기 · 찾기까지 내 PC에서 하려면 파이썬이 필요하다 — `prompts/10`에 안내.

6부 요약

1. **답하기 상자는 옮길 수 있다**: claude.ai · Colab · 내 PC, 어디에 두든 프롬프트는 같다. 오늘은 Ollama로 내 PC에 뒀다
2. **Ollama = 앱 + 명령어**: 설치 1번, 모델 이름 1개(`qwen2.5:1.5b`), 명령어 여섯 개. 인터넷은 내려받을 때만
3. **자료가 PC 밖으로 안 나간다**: 5부 "올려도 되는 문서" 고민이 답하기 단계에서는 사라진다. 자르기 · 찾기는 아직 Colab
4. **대신 품질이 낮다**: 작은 모델은 더 틀린다. 그래서 규칙 4줄과 근거 조각이 더 중요하다

한 문장으로

문서 없이 물으면 500만 원, 조각과 규칙을 붙이면 80,000원. **모델이 아니라 프롬프트에 무엇을 넣느냐**가 답을 정한다.

오늘의 핵심 정리

3차시에서 배운 것

1. **AI는 우리 문서를 모른다.** 알게 하는 길은 셋: 다시 학습(파인튜닝) · 통째로 넣기 · **찾아서 넣기(RAG)**. 문서가 크고 자주 바뀌면 RAG
2. **RAG 4단계**: 자르기(청킹) → 숫자로(임베딩) → 찾기(유사도 상위 k) → 답하기(규칙 + 조각 + 질문). 모델은 그대로, 프롬프트만 바뀐다
3. **수동 RAG가 곧 원리다**: 찾은 조각을 복사해 claude.ai에 붙여 넣는 것과, 코드가 같은 일을 하는 것은 같다. 자동화는 포장이다
4. **규칙 4줄**: 조각만 근거로 · 없으면 "없습니다" · 조항 번호 인용 · 3문장 이내. 이 줄이 지어내기를 막는다
5. **틀리면 단계를 가른다**: 조각이 엉뚱하면 검색, 조각은 맞는데 답이 틀리면 생성. 근거를 보여 주는 챗봇만 고칠 수 있다
6. **어떤 문서를 어디에**: 외부 서버에는 공개·가상 문서만. 답하기는 Ollama로 **내 PC**에 둘 수 있다 — 4단계는 같고 모델의 자리만 바뀐다

★ Big Picture

1차시 "**어떻게 물어보느냐**", 2차시 "**잘 물어본 것을 어떻게 저장하느냐**", 오늘 "**AI가 모르는 자료를 어떻게 연결하느냐**". 세 가지 모두 프롬프트에 무엇을 넣느냐의 문제다.

집에서 이어하기

prompts/00_README.txt — 실습 파일 목록과 공통 규칙, prompts/08_my_document.txt — 집에서 하는 순서

1. 내 문서 하나

공개 문서나 직접 쓴 문서를 골라 실습 8을 처음부터. 조각 수와 첫 조각을 눈으로 확인

2. 질문 세트 10개

답이 있는 질문 7개, 표현을 바꾼 질문 2개, 없는 질문 1개. 정답과 근거를 먼저 적어 둔다

3. 틀린 질문 가르기

정답률과 없음 처리율을 재고, 틀린 것마다 검색 실패인지 생성 실패인지 적는다

한 바퀴의 완료 기준

질문 10개의 기록표가 채워졌고, 틀린 질문 하나를 골라 **한 가지**(자르기 방식 · 상위 k · 규칙 한 줄)만 바꿔 다시 잰 결과가 있다. 두 숫자가 어떻게 움직였는지가 오늘 배운 것의 증거다.

모든 실습은 개인 계정 · 공개 또는 가상 문서로. 노트북은 Drive의 사본에서 이어진다.



군-학 연계 프로그램 범용 교육

3차시 RAG 챗봇 — 내 문서에 답하는 AI, 문서 질의응답 시스템

서왕덕 경기대학교 AI컴퓨터공학부