군-학 연계 프로그램 범용 교육

sLLM 파인튜닝 — 작은 공개 LLM을 내 데이터로 학습시키기

서왕덕

경기대학교 AI컴퓨터공학부　6차시

26.10.21



목차

1. 실습 준비: Colab 열기와 GPU 켜기
2. 복습과 로드맵
3. 1부. 파인튜닝이란: 사전학습 위에 얹는 짧은 학습
4. 2부. 데이터셋: 질문-답 쌍을 만든다
5. 3부. 학습: 보조 다이얼을 돌린다
6. 4부. 한계와 비교: 환각, RAG, 그리고 선택
7. 5부. LLM의 미래: 시대의 요구, 작아지고, 싸지고, 생각하고, 한계와 발견
8. 정리



실습 준비

Colab 열기 · GPU 켜기 · 셀 1 미리 실행

오늘의 도구 3개



Colab + T4 GPU

3차시에 만든 Google 계정으로. 5차시처럼 **GPU를 켠다**. 설치할 것 없음



Kanana 1.5 (2.1B)

카카오가 공개한 한국어 소형 LLM. 노트북이 알아서 내려받는다(약 4GB)



unsloth

무료 T4 한 장으로 LLM을 학습시키는 공개 도구. 셀 1이 설치한다

오늘 GPU가 필수인 이유

3차시 RAG는 모델을 그대로 두고 **썼다**. 오늘은 모델을 **학습**시킨다. 21억 개 다이얼을 가진 모델에 300쌍의 예시를 세 번 보여 주는 데 T4로 약 3분, CPU로는 몇 시간이다. 그래서 오늘 노트북은 GPU가 없으면 셀 1에서 멈추게 해 두었다.

시작 전에 확인

Google 계정 로그인이 돼 있는가(3차시 계정). 비밀번호를 잊었으면 지금 손을 든다. 오늘 쓰는 데이터는 전부 가상 회사(민트상사) 자료다. 업무 자료는 올리지 않는다.

Colab 열기와 노트북 올리기 (5차시와 같다)



순서

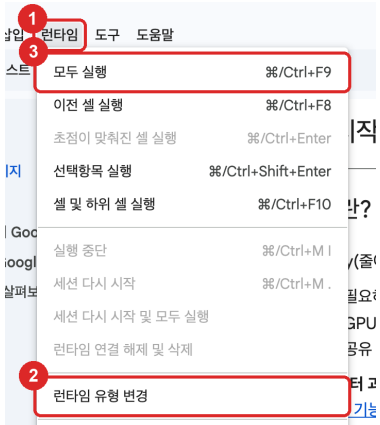
1) 메일 첨부 `sllm_finetune.ipynb` 를 **바탕화면에 저장**
2) `colab.research.google.com` 접속, 오른쪽 위 로그인
3) 메뉴 (1) **파일** → (2) **노트 업로드** → 바탕화면의 파일 선택
4) 제목이 `sllm_finetune.ipynb` 이고 옆에 "모든 변경사항이 저장됨" 이면 내 Drive에 들어간 것. 사본 저장은 안 해도 된다

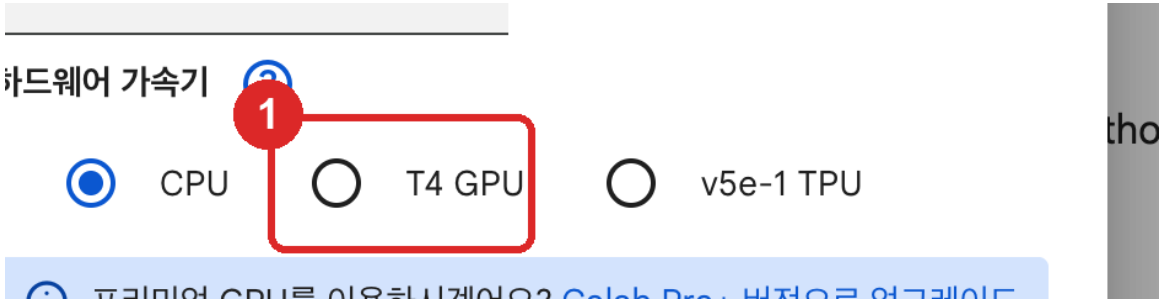
3차시와 같은 점

셀 왼쪽 ▶를 위에서부터 하나씩. 바꾸는 줄은 `# <-- 바꿔 보세요`뿐. 빨간 글씨는 두고 손을 든다.

메일을 못 받았으면 옆 사람 USB의 배포 zip `notebook/` 폴더에 같은 파일이 있다.

GPU 켜기: 오늘은 필수





메뉴 런타임 → 런타임 유형 변경 → T4 GPU → 저장

5차시와 똑같다. 왼쪽이 메뉴, 오른쪽이 대화상자. **T4 GPU**를 고르고 저장. 셀을 돌린 뒤 바꾸면 노트북이 다시 시작되므로 **셀 1보다 먼저** 한다.

GPU가 안 잡히면

무료 Colab은 GPU를 보장하지 않는다. "사용 가능한 GPU가 없습니다"가 뜨면 몇 분 뒤 다시 시도하고, 그래도 안 되면 옆 사람 화면으로 함께 진행한다(오늘 노트북은 CPU로는 돌지 않게 해 두었다).

실습 0-1: Colab + GPU 체크리스트 (6분)

prompts/01_colab_gpu_setup.txt — 순서 전문과 안 될 때 표

하나씩 눈으로 확인

✓ Google 계정으로 로그인했고 오른쪽 위에 프로필 아이콘이 보인다
✓ 노트북 제목이 `sllm_finetune.ipynb` 이고 옆에 **"모든 변경사항이 저장됨"** (파일 → 노트 업로드)
✓ 런타임 유형이 **T4 GPU**다 (런타임 → 런타임 유형 변경)
✓ 브라우저의 "비밀번호 저장" 제안은 **거절**했다(공용 PC)

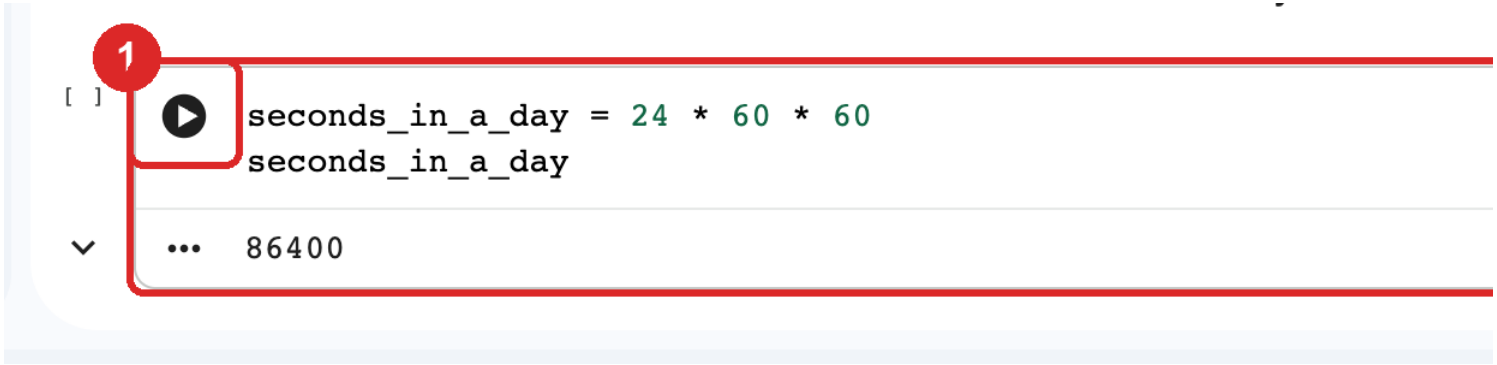
5분 규칙

5분 넘게 막히면 손을 든다. 로그인 · 업로드 · GPU 세 가지는 옆에서 화면을 한 번 보는 것이 가장 빠르다.

먼저 끝난 사람

다음 슬라이드의 **셀 1**을 바로 누른다. 약 5분 걸리는 설치와 모델 내려받기를 강의 중에 미리 끝내 두는 것이다.

실습 0-2: 셀 1 미리 실행 (5분, 기다리는 동안 강의 시작)



▶ 셀 1 왼쪽의 ▶를 누른다 — 이렇게 나오면 정상

회색 글씨가 한참 흐른 뒤 설치 끝 (N분), GPU: Tesla T4, 모델: kakaocorp/kanana-1.5-2.1b-instruct-2505 다이얼 2.09B개, 시험 질문의 답 한 줄 ("20대 대학생입니다" 같은 엉뚱한 자기소개도 정상), 마지막에 **준비 완료** (3.5분). T4 실측: 설치 1.3분 + 모델 받기, 합계 3.5분(새 세션 기준).

⚠ GPU 없음이 나오면

런타임 유형을 T4로 바꾸지 않은 것. 앞 슬라이드대로 바꾸면 노트북이 **다시 시작**되므로 셀 1을 한 번 더 누른다.

⧗ 기다리는 동안

탭을 닫지 않는다. 다음 섹션(복습 · 로드맵 · 1부)을 듣는다. 끝나면 셀 왼쪽 괄호에 숫자 [1]이 생긴다.



복습과 로드맵

쓰는 AI에서 가르치는 AI로

오늘 수업 로드맵 (120분)

시간	구간	내용	실습
12분	실습 준비	Colab · 노트 업로드 · T4 GPU · 셀 1 미리 실행	실습 0-1 · 0-2
5분	복습 · 로드맵	3 · 4 · 5차시 연결 · 오늘의 결과물 · 준비 원칙	—
17분	**1부** 파인튜닝이란	사전학습과 미세조정 · 공개 모델 · LoRA 보조 다이얼	실습 1
19분	**2부** 데이터셋	질문-답 쌍 · 데이터 2종 · 몇 개면 되나 · 내 상담 AI	실습 2 · 3
27분	**3부** 학습	에포크 · 손실 · 설정값 · 학습 · 전후 비교	실습 4 · 5
23분	**4부** 한계와 비교	환각 · 파인튜닝 vs RAG · 선택표 · 저장과 재사용	실습 6 · 7 · 8
12분	**5부** LLM의 미래	시대의 요구 · 작아지고 싸지고 생각한다 · 한계 · 발견	—
5분	정리	핵심 정리 · 집에서 이어하기 · PC 정리	—

◎ 오늘의 목표 하나

공개 소형 LLM에 가상 회사의 응대 데이터 300쌍을 학습시켜 **학습 후에는 우리 회사 말투로 답하는** 결과를 각자의 Colab에서 만들고, 그 모델이 **못 하는 것**(숫자 · 모르는 것)을 RAG와 비교해 확인한다. 실습 전문은 `prompts/`, 00_README부터.

3 · 4 · 5차시에서 오늘로



3차시: 세 가지 길

우리 문서를 알게 하는 길 셋 — 파인튜닝 · 통째로 넣기 · 검색해서 넣기(RAG). 그날은 셋째 길을 걸었다



4차시: 다이얼

신경망은 다이얼 뭉치. 예시를 보여 주면 틀린 만큼 다이얼이 스스로 돌아간다(학습)



5차시: 학습 전 · 후

공개 모델 위에 서명 사진 143장을 얹어 2분 학습. 학습 전엔 못 찾고 후엔 찾았다

오늘은 첫째 길

3차시 표의 **파인튜닝** 칸에 "비싸다 · 규정이 바뀌면 다시 학습 · 출처가 안 남는다"고 적었다. 오늘 그 길을 직접 걸어 본다. 5차시에서 사진으로 한 것(공개 모델 + 내 데이터 + 몇 분 학습 + 전후 비교)을 **글을 다루는 LLM**으로 똑같이 하고, 표의 "한계"가 정말인지 확인한다.

그대로 가져오는 것

3차시의 민트상사 규정집과 RAG 코드(셀 8), 4차시의 "다이얼", 5차시의 Colab + T4와 전후 비교 습관.

오늘의 결과물: 민트상사 상담 AI

학습 전 (공개 모델)

Q 주문한 의자가 아직 안 왔어요. 언제 오나요?

A "의자 주문을 하셨는데 아직 도착하지 않았다니, 기다리고 계시겠네요! 제가 직접 배송 일정을 확인할 수는 없지만, 보통 주문 후 1~3일 이내에 ···" — 친절하지만 민트상사를 모른다 (T4 실측)

학습 후 (300쌍 · 4분)

Q 같은 질문

A "안녕하세요, 민트상사 고객센터입니다. [확인] 출고와 도착 시점을 확인하셨습니다. [안내] 평일 14시 이전에 결제가 완료된 주문은 당일 출고되어 다음 날 도착하고 ··· [다음 단계] 마이페이지 ¿ 주문내역에서 송장번호를 ···" (T4 실측)

완성 기준 3개

✓ 같은 질문 10개의 **학습 전 · 후 답**을 나란히 받았다
✓ 내가 정한 이름을 상담 AI가 **말한다**
✓ 모르는 질문에서 **지어내는 것**을 봤고, RAG를 붙여 고쳤다

소재: 민트상사 고객센터

3차시의 가상 회사. 사무용품 · 사무가구 유통. 고객 응대 200쌍은 모두 오늘을 위해 만든 가상 데이터, 규정 Q&A 100쌍은 3차시 규정집에서 뽑았다.

준비 원칙 (1~5차시와 동일)



개인 계정

Google 계정은 개인 이메일로 만든 것



가상 데이터만

오늘 학습 데이터는 전부 가상. 내 예시도 가상의 상담 문장으로



업무 자료 금지

실제 민원 · 실제 규정 · 개인정보는 넣지 않는다



PC 초기화

노트북은 Drive에 남는다. 학습 결과(어댑터)는 수업 끝에 내려받는다

⚠ 학습 데이터는 모델 안에 남는다

3차시 문서는 프롬프트에 잠깐 붙였다 떼는 것이었다. 오늘 데이터는 **다이얼에 새겨진다**. 학습된 모델 파일을 누가 가져가면 그 안의 문장이 되살아날 수 있다. 실제 업무에서 파인튜닝을 하려면 "이 데이터가 모델 밖으로 새도 되는가"를 먼저 묻는다. 민트상사 규정집 제24조와 같은 이유다.

✋ 5분 규칙

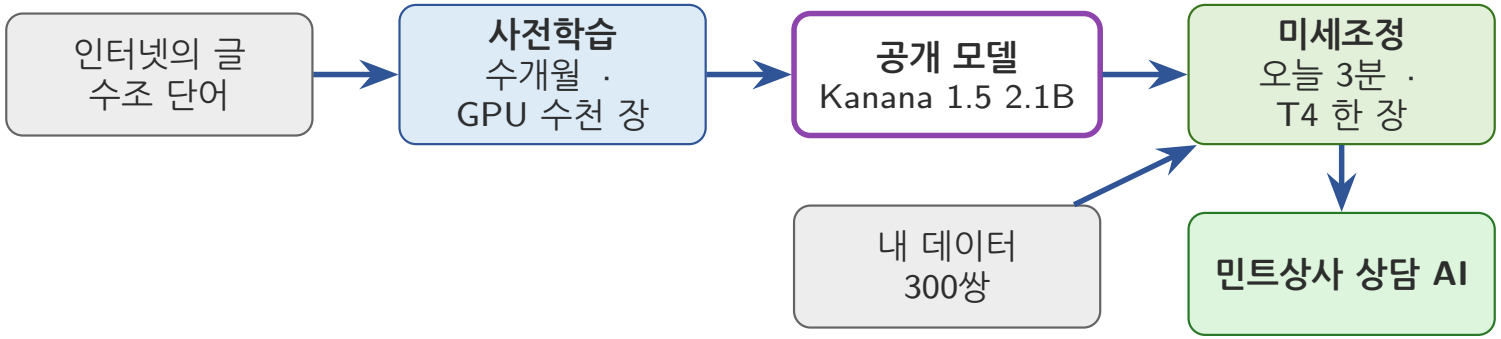
5분 넘게 막히면 손을 든다. 에러의 빨간 글씨는 지우지 말고 그대로 둔다.



1부 파인튜닝이란

사전학습과 미세조정 · 공개 모델 · LoRA 보조 다이얼

두 단계: 사전학습, 그리고 미세조정



파인튜닝(fine-tuning, 미세조정)

이미 사전학습된 모델의 다이얼을 **내 예시로 조금 더** 돌리는 것. 말을 처음부터 가르치는 것이 아니라, 말을 다 배운 모델에게 **우리 회사 방식**을 짧게 가르친다. 그래서 데이터 수백 개 · 몇 분으로 된다. 5차시의 "서명 학습"이 사진판, 오늘이 글판.

사전학습은 우리가 안 한다

왼쪽 두 칸은 카카오 · 구글 · 메타 같은 곳이 하고 결과(다이얼 뭉치)를 공개한다. 우리는 오른쪽 두 칸만 한다. 공개된 다이얼 뭉치를 "공개 모델" 또는 "오픈 웨이트 모델"이라 부른다.

공개 모델: 내려받을 수 있는 다이얼 뭉치

오늘의 모델: Kanana 2.1B

Kanana 1.5, 카카오 공개(2025년 5월). 다이얼 **21억 개**, 파일 약 4GB. Apache 2.0 라이선스 — 상업 이용 · 수정 · 재배포 자유. 한국어 학습 비중이 커서 한국어 답이 자연스럽다. 모델 이름 뒤의 `instruct`는 "질문-답 형식을 이미 배운 판"이라는 뜻.

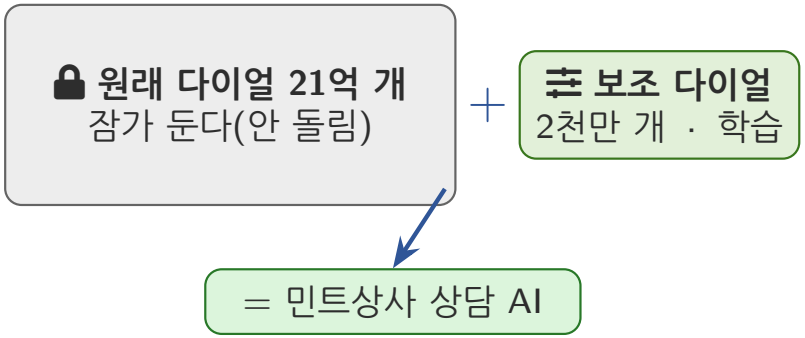
sLLM(소형 언어 모델)

다이얼 수십억 개 이하의 LLM. 1~3차시의 claude.ai 같은 모델은 수천억 개 이상이라 빌려 쓴다. 소형은 GPU 한 장에 올라가므로 **내 서버에서 돌리고 내 데이터로 고칠 수** 있다. 그 대신 아는 것이 적고 실수가 잦다 — 그래서 가르친다.

구분	다이얼 수	어디서 도나	오늘과의 관계
claude.ai (1~3차시)	비공개(수천억 이상)	회사 서버, 빌려 씀	고칠 수 없다. 프롬프트 · RAG로 다룬다
Kanana 1.5 2.1B (오늘)	21억	Colab T4 한 장	내려받아 **학습**시킨다
Qwen2.5 1.5B (3차시 셀 7)	15억	Colab T4 한 장	3차시에 RAG의 "답하기"로 썼다

공개 모델은 Hugging Face라는 저장소에서 이름으로 내려받는다. 노트북 셀 1의 `MODEL_ID`가 그 이름이다. 2026년 기준 수십만 개가 올라와 있다.

전체 다이얼 대신 보조 다이얼: LoRA



LoRA: 보조 다이얼

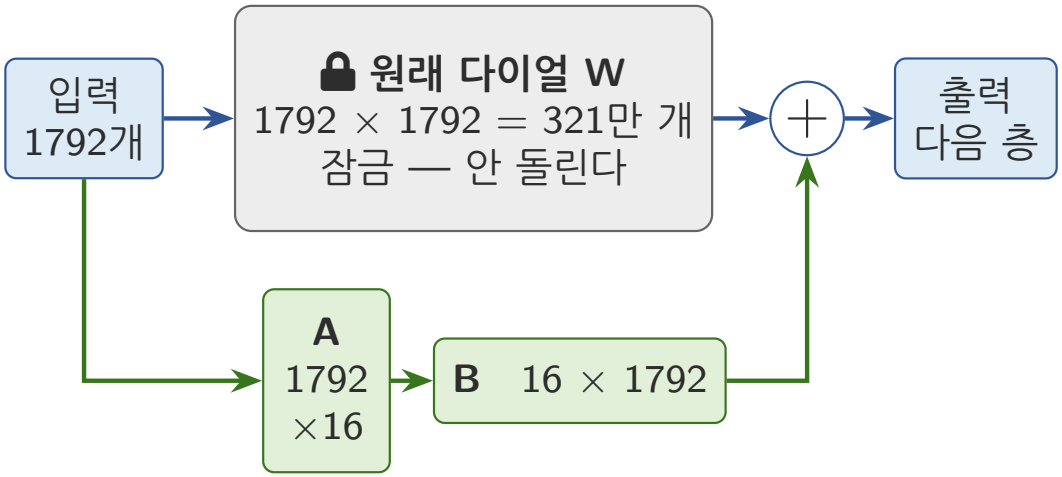
LoRA(Low-Rank Adaptation). 21억 개를 전부 돌리는 대신, 각 층 옆에 **작은 보조 다이얼**을 붙이고 그것만 돌린다. 오늘은 전체의 약 **1%**(2천만 개). 결과는 거의 같은데 메모리와 시간이 수분의 일로 준다. 학습 결과도 보조 다이얼 파일(수십 MB)만 저장하면 된다.

비유

피아노를 새로 만들지 않고 몇 개 현만 조율한다. 원래 소리는 그대로, 우리 곡(말투 · 형식)에 맞춘다.

```
>_ 셀 5의 첫 줄: 다이얼: 전체 2.09B개 중 학습하는 보조 다이얼 23.0M개 (1.10%) (T4 실측)
— 보조 다이얼 수는 LORA_R(기본 16)에 비례한다.
```

LoRA 한 장 그림: 어디에 붙고, 무엇만 돌리고, 무엇을 저장하나



보조 다이얼 A · B = 5만 7천 개(W의 1.8%) — 학습 때 도는 것은 이것뿐. 폭 16이 `LORA_R`. 넓히면 보조 다이얼이 그만큼 는다.

모델 전체로는

이 자리가 층마다 7곳(q · k · v · o · gate · up · down) × 32층 = **224곳**. 보조 다이얼 합계 2,300만 개 = 전체 21억의 **1.1%**(셀 5 첫 줄).

저장과 배포

셀 9: 어댑터(A · B 224쌍) **109 MB**만 저장 · 내려받기. 원래 4.2 GB는 누구나 받는 공개 모델이라, 어댑터만 건네면 상대 PC에서 다시 붙는다.

답할 때는 W와 B · A를 **합쳐 한 번에** 계산하므로 느려지지 않는다. 보조를 떼면(셀 8의 `adapter=False`) 원래 모델 그대로 — 같은 모델로 세 답을 비교할 수 있는 이유.

압축해서 올리기: 4비트(QLoRA)와 오늘의 선택

4비트 압축(QLoRA)

다이얼 하나를 보통 16비트(소수 자릿수 많게)로 저장한다. 이를 **4비트**로 뭉뚱그리면 메모리가 1/4. 7~8B 모델도 T4 한 장에 올라간다. 정밀도는 조금 잃지만 LoRA와 함께 쓰면 결과 차이가 작다.

오늘은 압축 안 함

2.1B 모델은 16비트 그대로 약 4GB라 T4(15GB)에 여유 있게 올라간다. 셀 1의 `load_in_4bit=False`가 그 선택. 집에서 8B 모델을 쓰려면 `True`로 바꾼다.

모델 크기	16비트 메모리	4비트 메모리	T4(15GB)에서
2B (오늘)	약 4GB	약 1.5GB	둘 다 됨. 16비트가 더 빠르다
8B	약 16GB	약 5GB	4비트로만
70B	약 140GB	약 40GB	안 됨(GPU 여러 장)

unsloth가 하는 일

이 LoRA · 4비트 · 메모리 절약을 한 줄 명령으로 묶어 준 공개 도구. 같은 학습을 보통 방식보다 약 2배 빠르게, 메모리는 절반 이하로 돌린다고 밝힌다. 무료 Colab T4를 공식 지원 환경으로 둔다.

노트북 사용 규칙 3가지

1. 위에서 아래로
셀 1부터 순서대로 ▶. 앞 셀의 결과 (모델 · 데이터)를 뒤 셀이 쓴다

2. 바꾸는 줄만 바꾼다
<-- 바꿔 보세요 줄의 이름 · 숫자만. 따옴표는 남긴다

3. 빨간 글씨는 두고 손
대부분 "셀 1 안 돌림" "GPU 안 켬" "순서 건너뜀"

셀	하는 일	실습	시간
1	준비: 도구 설치 · 모델 내려받기	0-2	약 5분
2	학습 전 — 시험 질문 10개	1	약 1분
3 · 4	데이터 300쌍 보기 · 내 예시 추가	2 · 3	바로
5	학습(LoRA)	4	약 3분
6	학습 후 — 같은 질문, 전 · 후 비교	5	약 1분
7 · 8	모르는 것을 물으면 · 파인튜닝 vs RAG	6 · 7	약 2분
9 · 10	저장 · 다시 불러오기 · (선택) 대화	8	약 1분

셀마다 첫 줄 주석에 번호와 하는 일이 있다. 시간은 T4 실측이며 사람마다 조금 다르다.

실습 1: 학습 전 모델에 시험 질문 10개 (4분)

prompts/02_before_questions.txt — 질문 10개와 기록표

▶ 셀 2 ▶ — 이렇게 나오면 정상

Q: 질문, A(학습 전): 답이 10번 되풀이된다. 고객 문의 5개에는 **일반 상식** 수준의 긴 답(민트상사를 모른다), 규정 5개에는 **그럴듯한 숫자**가 나온다. 전부 틀려도 정상이다 — 이것이 "학습 전"의 기준선이다. 답은 BEFORE에 저장되어 셀 6에서 다시 쓴다.

기록표에 적을 것

✓ 고객 문의 5개: "민트상사"라는 말이 답에 있는가 (O/X)
✓ 규정 5개: 숫자가 규정집과 맞는가 (O/X, 규정집은 docs/mint_rules.txt)
✓ 없는 항목(주차비 · 육아휴직)에 "없다"고 했는가

왜 먼저 묻나

5차시에서 "학습 전엔 서명을 못 찾는다"를 먼저 본 것과 같다. 전후 비교는 **같은 질문 · 같은 설정**이어야 한다. 그래서 무작위성을 꺼 두었다(같은 질문이면 늘 같은 답).

1부 요약

네 줄

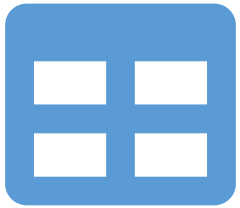
1) LLM은 두 단계로 만들어진다. **사전학습**(남이 함, 수개월) + **미세조정**(우리가 함, 몇 분).
2) 공개 모델은 내려받을 수 있는 다이얼 뭉치. 오늘은 카카오 Kanana 1.5 2.1B(Apache 2.0).
3) **LoRA**: 원래 다이얼은 잠그고 보조 다이얼(약 1%)만 돌린다. 결과는 수십 MB 파일.
4) 큰 모델은 4비트로 압축해 올린다(QLoRA). 오늘의 2B는 압축 없이 T4에 들어간다.

지금까지 한 것

셀 1(설치 · 모델) → 셀 2(학습 전 답 10개 저장). 기록표에 O/X.

→ 다음

2부 데이터셋. 모델에게 무엇을 어떤 모양으로 보여 줄지. 오늘의 300쌍을 열어 보고 내 예시를 더한다.



2부 데이터셋

질문-답 쌍 · 오늘의 데이터 2종 · 몇 개면 되나 · 내 예시

데이터 = 질문-답 쌍

한 쌍의 예 (SERVICE 1번)

Q 배송비는 얼마예요?
A 안녕하세요, 민트상사 고객센터입니다.
[확인] 배송비 기준을 문의하셨습니다.
[안내] 주문 금액 50,000원 이상이면 배송비가 무료이고 ···
[다음 단계] 장바구니 금액이 ···
더 궁금하신 점은 1588-0000(평일 09~18시)으로 문의해 주세요.

형식이 곧 가르침

5차시의 "사진 + 상자 좌표"가 오늘은 **질문 + 모범 답**이다. 모델은 답의 **내용**뿐 아니라 **모양**(인사 · 꺾쇠 소제목 · 맺음말)도 배운다. 200쌍이 같은 모양이면 모델도 그 모양으로 답한다.

파일 모양

한 줄에 한 쌍, `{"q": 질문, "a": 답}` (JSONL). 배포 zip `docs/data/`에 있다. 메모장으로 열린다.

모델이 실제로 보는 것은 조금 다르다

셀 4가 각 쌍을 **대화 템플릿**으로 감싼다: `<|start_header_id|>user<|end_header_id|>` 질문 `<|eot_id|>` ··· `assistant` ··· 답 `<|eot_id|>`. "여기부터 질문 · 답 · 끝"의 표시이며 모델마다 다르다. 셀 4가 첫 쌍을 보여 준다.

오늘의 데이터 2종: 말투를 가르치는 것, 지식을 가르쳐 보는 것

	SERVICE 200쌍	RULES_QA 100쌍	MY_PAIRS 3쌍
무엇	고객센터 응대. 주제 20개 (배송 · 반품 · 세금계산서 · 렌탈 · AS ···) × 질문 10개	사내 규정집 Q&A. 30개 조항마다 3∼4개	상담 AI의 이름 (셀 4에서 내가 정함)
답의 모양	인사 / [확인] / [안내] / [다음 단계] / 맺음말	"제N조에 따라 ···" 한두 문장	SERVICE와 같음
가르치려는 것	**말투와 형식** + 회사 정책 몇 가지	**숫자 지식**(한도 · 일수)	한 가지 사실을 몇 번 보여 주면 외우나
예상	잘 된다	부분적으로만 된다	3번 복제하면 외운다

왜 두 종류인가

파인튜닝이 **잘하는 일**(말투 · 형식 · 일 처리 방식)과 **잘 못하는 일**(낱낱의 사실을 정확히 외우기)을 한 번의 학습에서 같이 보기 위해서다. 같은 정책이 200쌍에 걸쳐 되풀이되는 SERVICE와 달리, RULES_QA의 숫자는 각각 서너 번만 나온다. 4부에서 이 차이가 환각과 RAG 이야기로 이어진다.

모두 가상 데이터다. 회사명 · 전화번호 · 이메일(`mint.example`)은 실존하지 않는다.

몇 개면 되나: 양보다 품질

100쌍: 최소
unsloth 공식 가이드의 하한. 말투 · 형식 하나를 익히는 데 충분. 오늘은 300

1,000쌍 이상: 안정
같은 가이드의 권장. 주제가 여럿이거나 답이 길면 이쯤부터 고르게 좋아진다

품질 > 양
좋은 500쌍이 흐릿한 10,000쌍을 이긴다. 틀린 답 하나가 모델에 그대로 새겨진다

팁: 데이터를 만들 때 지키는 다섯 가지

1) 답의 **모양을 통일**한다 — 모델은 모양을 가장 먼저 배운다. **2)** 질문은 **실제 고객처럼 다양하게** — 반말 · 존댓말 · 짧은 것 · 상황 설명. 오늘 20주제 × 10표현이 그것. **3) 틀린 답을 넣지 않는다** — 몇 쌍 빼는 것이 낫다. **4) 개인정보 · 실명**을 지운다 — 다이얼에 새겨진다. **5)** 일부(1할)는 **학습에 안 쓰고 남겨** 시험용으로 — 5차시의 검증 35장처럼. 오늘의 시험 질문 10개가 그것.

데이터는 상담 기록 · FAQ · 매뉴얼에서 뽑아 다듬는다. 큰 모델에 "이 FAQ를 질문 10가지 표현으로"라고 시켜 초안을 만들고 사람이 검수하는 방식이 흔하다(1차시 프롬프트).

실습 2: 데이터 300쌍 열어 보기 (3분)

prompts/03_data_look.txt — 볼 것 체크

▶ 셀 3 ▶ — 이렇게 나오면 정상

고객 응대 200쌍, 규정 Q&A 100쌍 그리고 예 3개(고객 응대 2개 · 규정 1개). 셀 자체가 길다(300줄) — 데이터가 셀 안에 들어 있어서다. 스크롤해서 아무 줄이나 읽어 본다.

체크

✓ 고객 응대 답 200개가 **전부 같은 모양**인가(인사 · 꺾쇠 · 맺음말)
✓ 같은 주제의 질문 10개가 **표현만 다른가**("배송비는 얼마예요" / "택배비 무료 되는 금액")
✓ 규정 Q&A의 답은 **조항 번호**로 시작하는가

생각해 볼 것

시험 질문 "주문한 의자가 아직 안 왔어요"는 SERVICE에 **그대로는 없다**. 비슷한 주제(배송 기간)만 있다. 학습 후 모델이 이 질문에 그 주제의 답을 하면 "외운 것"이 아니라 "배운 것"이다.

실습 3: 내 상담 AI 만들기 — 이름 · 말투 · 설정 5줄 (6분)

prompts/04_my_examples.txt

셀 4의 윗부분을 바꾸고 ▶

MY_NAME 이름 · STYLE 말투("기본" / "사극" / "해적" / "유치원" / "로봇" 중 하나) · MY_FACTS 가상 설정 5줄(고향 · 취미 · 좋아하는 음식 · 좌우명 · 비밀). REPEAT = 3은 그대로.
출력: 학습 쌍: 고객 응대 200 + 규정 100 + 내 예시 (3 + 20)x3 = 369, **말투 미리보기**(고객 응대 첫 쌍이 내 말투로), 내 설정 예, 토큰 길이, 모델이 보는 형식의 첫 쌍.

말투는 왜 바뀌나

300쌍의 답을 **문장 끝만 규칙으로 고쳐**("입니다" → "이옵니다" / "이다!" / "이에요~" / "임") 학습시킨다. 내용 · 숫자 · 형식은 같다. 모델이 배우는 것은 **답의 모양**이라서, 말투를 바꾼 사람은 학습 후 **모든 답**이 그 말투로 나온다 — 2부 1)의 실험.

설정 5줄은 왜 20쌍이 되나

설정 하나를 **질문 4가지**로 묻는 쌍을 만들고 3번 복제한다 → 설정 하나당 12번 본다. 낱낱의 사실은 "여러 번 · 여러 표현"이어야 남는다. 셀 6에서 데이터에 **없던 표현**으로 물어 외웠는지, 배웠는지 본다. 실제 개인정보는 넣지 않는다.

토큰: 한 쌍이 평균 145토큰, 최대 236(T4 실측). 셀 1의 MAX_LEN = 1024가 상한이라 오늘 데이터는 잘리지 않는다.

2부 요약

네 줄

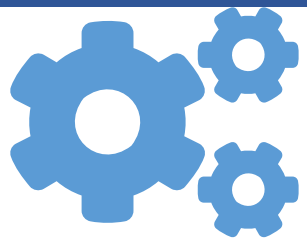
1) 데이터 = 질문-답 쌍. 모델은 답의 **내용과 모양**을 같이 배운다. 모양을 통일한다.
2) 각 쌍은 그 모델의 **대화 템플릿**으로 감싸서 넣는다(셀 4). 어디가 질문이고 어디서 끝나는지의 표시.
3) 최소 100쌍, 1,000쌍부터 안정. **품질** > **양**. 틀린 답 · 개인정보는 넣지 않는다. 시험용은 남겨 둔다.
4) 사실을 외우게 하려면 **여러 번 · 여러 표현**으로. 오늘 내 설정 5줄 × 질문 4가지 × 3복제가 그 실험.

지금까지 한 것

셀 3(300쌍 보기) → 셀 4(이름 · 말투 · 설정 5줄 → 369쌍 조립 · 템플릿 확인).

→ 다음

3부 학습. 설정값 세 개를 읽고 셀 5를 돌린다(3분). 손실 그래프를 읽고, 셀 6에서 전후를 비교한다.



3부 학습

에포크 · 손실 · 설정값 · 학습 · 전후 비교

학습이란: 다음 단어를 맞히며 다이얼을 돌린다

에포크(epoch)

369쌍을 **한 바퀴** 다 보는 것. 3 에포크 = 같은 쌍을 3번 본다. 5차시의 20 에포크보다 훨씬 적다 — 글의 LLM은 이미 말을 알아서 금방 배우고, 오래 보면 외워 버린다.

손실(loss)

모범 답의 **다음 단어를 얼마나 못 맞혔나**를 숫자 하나로. 낮을수록 좋다. 학습은 이 숫자를 줄이는 쪽으로 보조 다이얼을 돌리는 일(4차시의 내리막). 오늘은 답 부분만 세고 질문 부분은 세지 않는다.

셀 5가 보여 주는 것

보조 다이얼 수, 진행 막대(141스텝 = 369쌍 ÷ 8쌍 × 3바퀴), 끝에 학습 끝: `4.0`분, 스텝 `141`개, 손실 처음 `2.94` → 마지막 `0.45`(T4 실측), 메모리 6.3 GB, **손실 그래프**.

팁: 몇 에포크가 맞나

unsloth 공식 가이드: **1~3 에포크**. 그 이상은 효과가 작고 외우기(과적합)가 시작된다. 답이 제각각인 실제 데이터에서 손실이 **0.2 아래**면 외우고 있다는 신호. 5차시의 "300에서 시작"과 반대인 이유 — 사진 모델은 처음 보는 물체를 배우지만, 글 모델은 아는 말의 **쓰임새**만 고친다.

설정값 읽기: 바꿀 수 있는 두 개, 그대로 둘 것들

이름(셀 5)	오늘 값	뜻	공식 권고
`EPOCHS`	3	데이터를 몇 바퀴	1∼3
`LORA_R`	16	보조 다이얼 크기. 크면 더 많이 배우지만 더 느리고 외우기 쉬움	16 또는 32
`learning_rate`	2e-4	한 번에 다이얼을 얼마나 돌리나. 크면 빠르지만 불안정	2e-4에서 시작
배치	4×2	한 스텝에 8쌍을 보고 한 번 돌린다	유효 배치 8∼16
`warmup_steps`	5	처음 몇 스텝은 살살 돌린다	전체의 5∼10%
`weight_decay`	0.01	다이얼이 너무 커지지 않게 눌러 둔다(외우기 방지)	0.01∼0.1

팁: 처음에는 기본값, 바꾸는 건 하나씩

unsloth LoRA 하이퍼파라미터 가이드 요지: 학습률 `2e-4`, `r` 16∼32, `alpha` = `r`, 모든 층(attention + MLP)에 보조 다이얼, 1∼3 에포크로 시작한다. 결과가 나쁘면 **설정보다 데이터를 먼저 의심**한다. 바꿀 때는 한 번에 하나만 바꿔 전후를 비교한다(실습 10 선택: `EPOCHS = 1`).

`random_state = 3407`은 "같은 설정이면 같은 결과"를 위한 고정 난수. 옆 사람과 결과가 같은 이유다.

실습 4: 학습 (6분 — 돌아가는 4분은 다음 슬라이드를 듣는다)

prompts/05_train.txt — 기대 출력과 기록표

▶ 셀 5 ▶ — 이렇게 나오면 정상

첫 줄 다이얼: 전체 2.09B개 중 학습하는 보조 다이얼 23.0M개 (1.10%). 이어서 unsloth 로고 글씨와 진행 막대 141/141. 손실 숫자가 스텝마다 한 줄씩 찍히며 **내려간다**. 끝에 학습 끝: 4.0분, 스텝 141개, 손실 처음 2.94 → 마지막 0.45, GPU 메모리 최대 5.9 GB, 그래프. T4 실측 3.6분(두 번 재서 3.6 · 3.7).

기록표에 적을 것

✓ 학습 시간(분)
✓ 손실 처음 값과 마지막 값
✓ 그래프가 **내려가다 평평해지는가** / 들쭉날쭉인가 / 0 근처까지 떨어지는가 (오늘은 0.05 안팎 — 다음 슬라이드)

기다리는 동안 하지 말 것

탭을 닫거나 다른 셀을 누르지 않는다. 셀 왼쪽이 ■ 모양이면 돌아가는 중. 5분을 넘기면 손을 든다(T4가 아니라 CPU로 돌고 있을 가능성).

학습 곡선 읽기



세 구간

처음 2.7 — 말은 알지만 우리 형식은 모른다.
첫 바퀴(스텝 1~39) 2.7에서 0.1로 급히 — 인사 · 꺾쇠 · 맺음말의 **모양**과 주제별 답을 배운다.
둘째 · 셋째 바퀴 평균 0.09 → 0.05, 가장 낮을 때 0.006 — 답 20개를 **통째로 외운다**. 마지막 스텝의 0.45는 한 묶음이 튄 값이라 **숫자 하나가 아니라 그래프**를 본다.

⚠ 0.05까지 내려간 것은 외운 것이다 — 오늘은 그래도 된다

답 20개가 10번씩 되풀이되는 데이터라 외우는 것이 곧 목표. 답이 제각각인 실제 데이터에서 0.2 아래면 **과적합**을 의심하고 에포크를 줄인다. 끝까지 2 근처면 안 배운 것, 크게 튀면 학습률이 큰 것.

💡 **팁: 손실은 시험 점수가 아니다.** 학습 데이터에서 잰 숫자라 외워도 낮아진다. 진짜 점수는 **안 보여준 질문**(셀 6의 10개)으로 잰다. 실무에서는 시험용 쌍 수십 개를 떼어 두고 학습마다 자동 채점한다.

실습 5: 학습 전 · 후 비교 — 고객 문의 · 내 설정 (7분)

prompts/06_before_after.txt — 기록표

✗ 학습 전 (셀 2)

Q 견적서를 받고 싶은데 어디로 연락하나요?

A "견적서를 받고 싶으시다면, 다음과 같은 방법으로 연락하실 수 있습니다: 1. 직접 문의 ··· 2. 온라인 문의 ··· 3. 전화 문의 ···" — 일반론, 회사명 · 연락처 없음 (T4 실측)

✓ 학습 후 (셀 6)

Q 같은 질문

A "안녕하세요, 민트상사 고객센터입니다. [확인] 견적서 발급 절차를 확인하셨습니다. [안내] ··· 정식 견적서는 영업팀(sales@mint.example)으로 요청하시면 1 영업일 안에 ···" (T4 실측)

▶ 셀 6 ▶ — 질문 10개마다 [학습 전] [학습 후] 두 답

고객 문의 5개: 답이 **민트 형식**(고른 말투)으로 바뀌었나, 내용이 정책과 맞나. T4 실측: 1~4번 형식 · 내용 맞음. 5번(노트북 거치대, 배운 적 없는 주제)은 형식만 완벽, 내용은 엉뚱한 "가구 설치 서비스". 이어서 **내 이름**과 **내 설정 5줄**(데이터에 없던 표현으로): T4 실측: 5줄 모두 내가 적은 값이 그대로 나왔다(기본 · 해적 말투 둘 다).

1~4번은 데이터에 **그대로 없던 문장**이다. 그래도 맞게 답하면 200쌍에서 **규칙**을 뽑아낸 것 — 파인튜닝이 가장 잘하는 일. 옆 사람과 비교: 같은 질문, 다른 말투.

전 · 후 비교 — 규정 질문: 숫자는 어디까지 외웠나

질문	정답(규정집)	학습 전 (T4 실측)	학습 후 (T4 실측)
숙박비 한도(데이터에 그대로)	80,000원 (제15조)	"5만~10만 원" 일반론	**80,000원 · 제15조** ✓
호텔비(같은 뜻, 다른 말)	80,000원 (제15조)	호텔 시세 15~20만	80,000원 ✓ 조항 "제28조" ✗
자기계발비 작년 대비(부칙)	30만 → 50만	"자료가 필요하다"	"제23조 전년도 기준 심사" 지어냄
주차비(규정집에 없음)	"없다"	"기관마다 다르다"	"제28조 1일 5,000원" 지어냄
육아휴직(규정집에 없음)	"없다"	법정 1년(일반 법령)	"제10조 1년" 지어냄

⚖ 읽는 법

그대로 있던 질문은 맞히고, 말을 바꾸면 숫자는 맞아도 조항이 흔들리고, 없는 것은 **조항 번호까지 붙여 지어낸다**. 학습 전엔 "다르다 · 자료가 필요하다"던 모델이 학습 후 **더 단정적으로** 틀린다 — "제N조에 따라"라는 모양을 배웠기 때문.

💡 내 이름(3쌍 × 3복제)은 잘 나온다. 사실도 **충분히 여러 번 · 여러 표현**이면 들어간다. 다만 규정이 바뀔 때마다 그만큼 다시 해야 하고, "없다"는 따로 가르쳐야 한다.

3부 요약

네 줄

1) 학습 = 모범 답의 다음 단어를 맞히며 보조 다이얼을 돌리기. 369쌍 × 3바퀴 = 141스텝, T4 약 4분.
2) 설정값은 기본값(학습률 2e-4 · r 16 · 1∼3 에포크)에서 시작, 하나씩 바꾼다. 데이터를 먼저 의심한다.
3) 손실 곡선: 2.9에서 0.05 안팎으로(셋째 바퀴 평균). 오늘은 외우는 것이 목표라 괜찮지만, 실제 데이터에서 0.2 아래면 과적합을 의심. 손실은 시험 점수가 아니다.
4) 전후 비교: **말투 · 형식 · 절차**는 확실히 배운다. **낱낱의 숫자**는 반쯤, 모르는 것은 조항까지 붙여 지어낸다.

지금까지 한 것

셀 5(학습 약 4분 · 손실 그래프) → 셀 6(전후 비교 10개 + 내 이름 + 내 설정 5줄).

→ 다음

4부. 못 하는 것을 정면으로 본다 — 모르는 질문에 지어내기(환각), 그리고 3차시 RAG를 붙여 고치기. 마지막에 저장.



4부 한계와 비교

환각 · 파인튜닝 vs RAG · 선택표 · 저장과 재사용

실습 6: 모르는 것을 물으면 (4분)

prompts/07_unseen.txt — 질문 5개와 기록표

▶ 셀 7 ▶ — 학습 데이터에 없는 질문 5개

퇴직금 계산 · 대표이사 이름 · 복합기 **렌탈료 금액**(렌탈은 배웠지만 금액은 없음) · 야간 배송 · 해외 배송. 답마다 기록표에 **"없다고 했다"** / **"지어냈다"** / **"딴 답을 했다"** 중 하나에 표시한다.

흔히 나오는 답 (T4 실측)

Q 민트상사 대표이사는 누구인가요?

A "제10조에 따라 대표이사는 사내이사 중에서 선임하며, 임기는 3년입니다." — 조항도 내용도 **없는 것**. 퇴직금도 "제10조 · · · 퇴직수당". 렌탈료 · 야간 · 해외 배송은 **비슷한 주제의 외운 답을 그대로**(동문서답).

환각(hallucination)

모르는 것을 **그럴듯하게 지어내는 것**. 1차시의 그 현상이 파인튜닝 후엔 **더 위험**하다 — 우리 회사 형식과 이름으로 틀린 숫자를 말하고, 고객은 그것을 공식 답변으로 읽는다.

왜 지어내나: 모델은 "다음 단어"를 고르는 기계다. "[안내] 월 렌탈료는" 다음엔 어떤 숫자든 와야 문장이 된다. 데이터에 "모르면 모른다"는 예시가 없었으니 그 선택지가 없다. 고치는 길 둘 — 그런 예시를 넣거나, 답하기 전에 근거를 찾아 붙이거나(RAG).

실습 7: 파인튜닝 vs RAG — 같은 모델, 근거를 붙이면 (6분)

prompts/08_rag_compare.txt

▶ 셀 8 ▶ — 규정 질문 6개마다 답 셋과 찾은 조항

3차시 코드 그대로 조항 31개 → 임베딩 → 가까운 조항 3개 → 규칙 4줄과 함께 프롬프트에 붙여 묻는다. 답 셋: **[파인튜닝만]** · **[파인튜닝 + RAG]** · **[원래 모델 + RAG]**(보조 다이얼을 잠시 뗀 것). 첫 실행은 임베딩 모델 내려받기 30초.

파인튜닝만

Q 출장 가서 호텔비는 얼마까지 나오나요?

A "제28조에 따라 숙박비는 1박 80,000원 한도입니다." — 숫자는 맞고 **조항이 틀림** (T4 실측)

파인튜닝 + RAG

Q 같은 질문

A "제4장 출장 제15조에 따라 숙박비는 1박 80,000원 한도입니다." — 조항까지 맞음. 찾은 조항: 제15 · 16 · 17조 (T4 실측)

기록표: 질문 6개 × 답 셋 O/X. 있는 것(숙박비 2개)은 RAG가 조항까지 고친다. 없는 것(주차비 · 육아휴직 · 퇴직금)에서 세 답이 어떻게 다른지 본다 — 다음 슬라이드.

없는 것을 물었을 때: 답 셋 비교 (T4 실측)

질문 (정답)	파인튜닝만	파인튜닝 + RAG	원래 모델 + RAG
호텔비 (80,000원 · 제15조)	80,000원 ✓ 제28조 ✗	80,000원 · 제15조 ✓	"규정집 (1)에 따르면 ··· 80,000원" ✓
자기계발비 작년 대비 (30만 → 50만)	"제23조 전년도 기준 심사" 지어냄	"제28조 연 500,000원" 반만	"규정집에 없습니다" — 부칙을 못 찾음
주차비 (없음)	"제28조 1일 5,000원" 지어냄	"제21조 접대비 ···" 동문서답	**"규정집에 없습니다"** ✓
육아휴직 (없음)	"제10조 1년" 지어냄	"제14조 2년" 지어냄	**"규정집에 없습니다"** ✓
퇴직금 (없음)	"제10조 30일 이내 퇴직수당" 지어냄	"제24조 1일당 150,000원" 지어냄	**"규정집에 없습니다"** ✓

⚠ 파인튜닝은 RAG의 규칙도 이긴다

같은 프롬프트("조각에 없으면 규정집에 없습니다라고만 답한다")에 **원래 모델은 셋 다 "없습니다"**, 파인튜닝된 모델은 **"제N조에 따라 ···"를 지어냈다**. 100쌍 전부가 그 모양이었기 때문 — 새겨진 습관이 프롬프트 지시보다 세다. "없다" 예시를 데이터에 **같이 넣어야** 고쳐진다 (집에서 이어하기).

💡 있는 것은 RAG가 고친다. 없는 것은 모델의 습관이 결정한다. 자기계발비의 "없습니다"는 검색 실패(부칙). **"모른다"도 데이터로** 가르친다.

선택표: 프롬프트, RAG, 파인튜닝 — 언제 무엇을

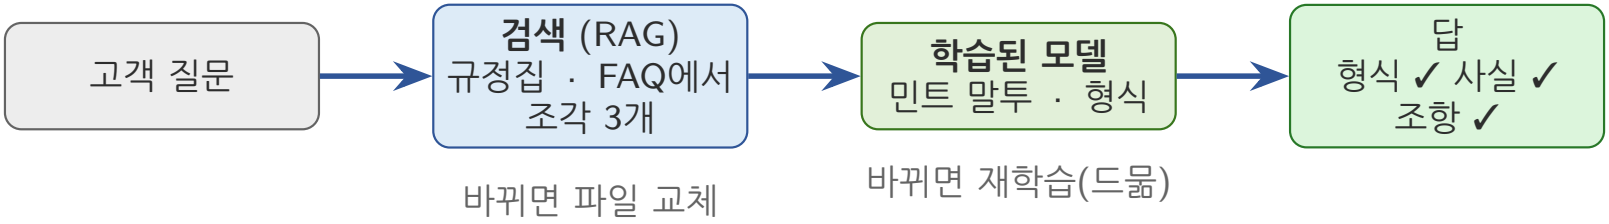
	프롬프트 (1 · 2차시)	RAG (3차시)	파인튜닝 (오늘)
잘하는 것	한 번 쓰는 지시 · 형식	**사실 · 최신 문서** · 출처 표시	**말투 · 형식 · 절차**가 몸에 밴 모델
못하는 것	매번 길게 붙여야 함	검색이 틀리면 답도 틀림	사실은 반쯤, 모르면 지어냄, 갱신마다 재학습
비용	0	문서 준비 + 검색 시스템	데이터 수백 쌍 + GPU 몇 분∼몇 시간
바뀌면	프롬프트 고침	파일 교체	**다시 학습**
오늘 증거	—	셀 8: 있는 것은 숫자 · 조항 맞음	셀 6: 형식 완벽 · 셀 7 · 8: 없는 것은 지어냄

고르는 순서

프롬프트로 되면 거기서 끝 → 문서를 알아야 하면 **RAG** → 그래도 말투 · 형식 · 속도 · 작은 모델이 필요하면 **파인튜닝**. 거꾸로 가면 비싸고 되돌리기 어렵다. 3차시 표의 "한계" 칸(비싸다 · 재학습 · 출처 없음)을 오늘 셀 6 · 7 · 8로 확인했다.

팁: 파인튜닝은 "무엇을 아는가"가 아니라 "어떻게 말하는가"를 바꾸는 도구로 쓸 때 실패가 적다. 사실은 RAG에 맡긴다.

둘을 합치면: 말투는 파인튜닝, 사실은 RAG



오늘 셀 8이 바로 이 구조

자주 안 바뀌는 것(말투 · 형식 · 절차 · 금칙어)은 모델에 넣고, 자주 바뀌는 것(가격 · 규정 · 재고)은 검색으로 붙인다. 실제 고객센터 AI 대부분이 이 조합이다. 모델은 작아도 되고(2B), 사실은 문서가 책임진다.

그래도 남는 것

검색이 엉뚱한 조각을 주면 모델은 그 위에서 틀린다(3차시 · 오늘 주차비). 파인튜닝한 모델은 "없습니다"를 잘 못 하므로 **"없다" 예시를 데이터에 넣고**, 그런 답을 **사람이 표본 검사**한다. 자동화는 평가까지 포함해야 끝난다(2부 팁 5번).

실습 8: 저장과 다시 불러오기 (4분)

prompts/09_save_reload.txt

▶ 셀 9 ▶ — 이렇게 나오면 정상

어댑터 폴더 `mint_lora: 109 MB` (원래 모델은 약 4.2 GB --- 바뀐 부분만 저장)(토크나이저 파일 포함) → 메모리를 비우고 어댑터 파일만으로 모델을 되살려 되살린 모델에게 → 안녕하세요, 민트상사 고객센터입니다. ··· '민트봇' → 브라우저가 `mint_lora.zip`(88 MB)을 내려받는다. T4 실측 약 1분.

어댑터는 보조 다이얼 파일

오늘의 산출물은 4GB 모델이 아니라 **88 MB짜리 zip**(어댑터, 원래 모델의 2%)이다. 원래 모델은 누구나 내려받을 수 있으니, 내 것은 "차이"뿐이다. 이메일로 보낼 수 있는 크기. 5차시 `best.pt`에 해당한다.

한 모델, 여러 어댑터

같은 Kanana 위에 고객센터용 · 규정 안내용 · 보고서 요약용 어댑터를 따로 두고 **갈아 끼운다**. 서버에는 모델 하나만 올리면 된다. 실무에서 LoRA를 쓰는 큰 이유.

⚠ Colab 서버의 파일은 연결이 끊기면 없어진다. zip을 내려받았는지 확인한 뒤 셀 10(선택)으로. 다음에 쓰는 법은 `prompts/12_home.txt`.

안 될 때: 증상별 조치

화면에 뜬 말	원인	조치
`AssertionError: GPU 없음` (셀 1)	런타임 유형이 CPU	런타임 → 런타임 유형 변경 → T4 → 셀 1 다시
`NameError: name 'model'`	셀 1을 안 돌렸거나 다시 시작됨	셀 1부터 다시 ▶
`NameError: name 'BEFORE'` (셀 6)	셀 2를 건너뜀	셀 2 → 셀 6
`NameError: name 'dataset'` (셀 5)	셀 3 · 4를 건너뜀	셀 3 → 4 → 5
"런타임 연결이 해제"	유휴 90분 또는 한도	런타임 → 다시 연결 → 셀 1부터
`OutOfMemoryError` (셀 5)	메모리 부족(다른 셀 중복 실행)	런타임 → 세션 다시 시작 → 셀 1부터
셀 5가 10분 넘게 돈다	T4가 아니거나 CPU	셀 1 첫 줄의 GPU 이름 확인. 없으면 위 첫 줄
답이 같은 말을 되풀이한다	작은 모델의 흔한 버릇	그대로 기록. 셀 5의 `EPOCHS`를 2로 줄여 다시
`SyntaxError` (셀 4)	따옴표를 지움	`MY_NAME = "이름"` 따옴표 복구

표 전문과 더 많은 증상은 `prompts/11_stuck.txt`. 5분 규칙은 그대로다.

4부 요약

네 줄

1) 파인튜닝한 모델은 모르는 것을 **우리 형식으로** 지어낸다(환각). 데이터에 "모른다"가 없었기 때문.
2) 같은 모델에 **RAG**를 붙이면 있는 것은 숫자 · 조항이 맞는다. 없는 것은 여전히 지어낸다 — 파인튜닝의 습관이 프롬프트 규칙을 이긴다(셀 8).
3) 고르는 순서: 프롬프트 → RAG → 파인튜닝. 말투 · 형식은 파인튜닝, 사실은 RAG. 둘을 합친다.
4) 산출물은 수십 MB **어댑터**. 한 모델에 여러 어댑터를 갈아 끼운다. 세션이 끝나기 전에 내려받는다.

지금까지 한 것

셀 7(환각 5개) → 셀 8(파인튜닝 vs RAG 6개) → 셀 9(어댑터 저장 · 재로드 · 내려받기) → (셀 10 대화).

→ 다음

5부. 실습은 끝. 오늘 만진 "작은 공개 모델"이 LLM 전체의 흐름에서 어디에 있는지 12분.



5부 LLM의 미래

시대의 요구 · 작아지고 · 싸지고 · 생각하고 · 한계 · 발견

시대의 요구: 전기, 칩, 그리고 주권



CERN 데이터센터 — 모델은 이런 곳에서 돈다



스리마일섬 원전 — AI 전기용 재가동 계약(2024, 목표 2027)

전기

데이터센터 전력 2024년 415 TWh(세계의 1.5%) → 2030년 945 TWh 전망(IEA). 원전까지 사는 이유

칩

세계 AI 계산 용량 해마다 3.3배. 나라마다 GPU 확보 경쟁 — 한국 정부도 2025년 말 1만 3천 장 확보, 2028년 5만 2천 장 목표

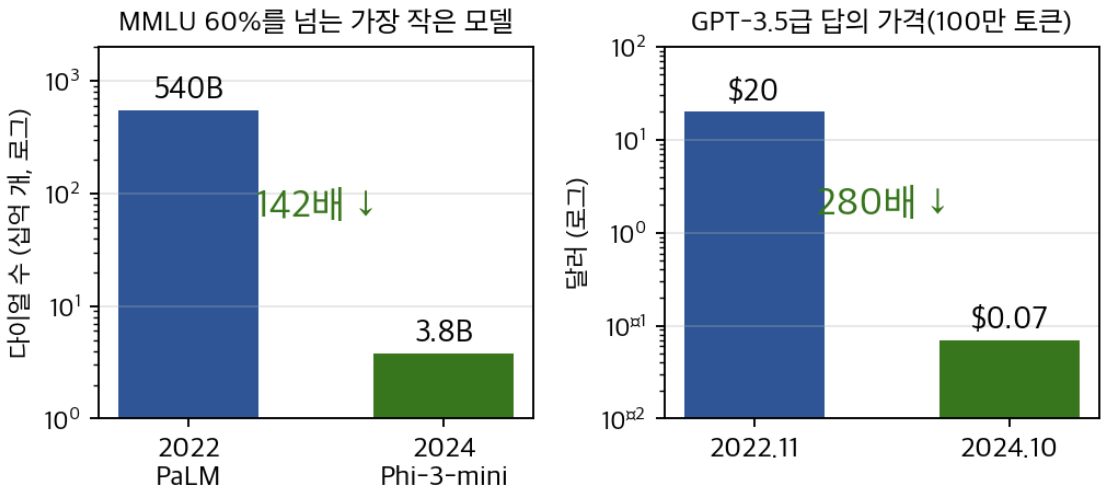
주권과 규칙

한국어 공개 모델(오늘의 Kanana 등), AI 기본법 2026-01 시행, EU AI법 범용 모델 의무 2025-08. 자료가 밖으로 안 나가는 모델을 찾는다

세 요구가 같은 쪽을 민다 — **작게, 가까이서, 우리 손으로**. 오늘 무료 GPU에서 돌린 2B 모델이 그 자리다.

출처: IEA, Energy and AI(2025-04) · Constellation(2024-09 · 2025-06) · 과기정통부(2025-12) · AI Index 2026. 사진: Florian Hirzinger, CC BY-SA 3.0 · 미국 에너지부(퍼블릭 도메인).

작아진다: 같은 점수를 142배 작은 모델이



2022 → 2024

시험(MMLU) 60%를 넘는 **가장 작은 모델**: 2022년 5,400억 개(PaLM) → 2024년 38억 개(Phi-3-mini), **142배**. 오늘의 Kanana(21억)가 그 흐름 위에 있다. 비결은 더 고른 데이터, 더 긴 학습, 큰 모델이 작은 모델을 가르치기(증류).

그래서: 기기 안으로

2026년 상반기 구글 · 마이크로소프트 · 애플 모두 100억 개 이하 모델을 내놓았고, 노트북에서 도는 모델이 1년 전 최상위와 겨룬다. 작은 모델은 **내 데이터로 고치기 쉽고**(오늘) **인터넷 없이** 돌며 자료가 밖으로 안 나간다. 3차시 6부의 Ollama가 그 입구였다.

출처: Stanford HAI, AI Index Report 2025(모델 크기 · 가격), 2026(기기 내 모델 동향).

싸진다: 같은 답이 18개월 만에 280분의 1

$ 가격

GPT-3.5급 답을 내는 비용이 100만 토큰(책 몇 권 분량)에 2022년 11월 $20에서 2024년 10월 $0.07로. **280배** 하락. 그 뒤로도 계속 내려간다.

계산

세계 AI 계산 용량은 2022년부터 해마다 3.3배씩, 2025년 기업 AI 투자는 $5,810억(전년의 2.3배). 공급이 늘고 모델이 작아지니 가격이 떨어진다.

그래서: 모델을 골라 쓴다(라우팅)

쉬운 일(분류 · 추출 · 형식 맞추기 · 오늘의 고객 응대)은 **작고 싼 모델**이, 어려운 추론만 **큰 모델**이 맡는 구조가 표준이 되고 있다. 2026년 AI Index는 조직의 88%가 AI를 쓴다고 보고한다 — 쓰는 곳이 많아질수록 "한 번에 얼마"가 설계의 중심이 된다.

오늘과의 연결

오늘 2B 모델을 무료 GPU로 3분 학습시킨 것이 2년 전엔 연구실 장비가 필요한 일이었다. 비용이 내려간 만큼 해 볼 수 있는 사람이 늘었고, 대신 **무엇을 가르칠지(데이터)**가 병목이 됐다.

출처: Stanford HAI, AI Index Report 2025 · 2026.

생각한다: 답하기 전에 시간을 쓰는 모델

추론 모델

2025년부터 모델이 답을 내기 전에 **풀이 과정을 길게 써 보고** 답하는 방식이 퍼졌다. 4차시 죄수의 딜레마에서 켠 "사고 모드"가 그것. 수십 초를 더 쓰는 대신 수학 · 코딩 · 계획에서 정확도가 크게 오른다.

시험이 바닥난다

코딩 시험 SWE-bench Verified는 1년 만에 60%에서 100% 가까이, 전문가 문제 모음 "Humanity's Last Exam"은 8.8%에서 38.3%로. 박사급 과학 · 경시 수학에서 사람 기준을 넘었다.

그런데 시험 점수가 전부가 아니다

같은 보고서는 시험 문제 자체의 오류(2∼42%)와 "시험 잘 보기"와 "일 잘하기"의 차이를 짚는다. **형식은 완벽한데 숫자가 틀린 답**(오늘 셀 7)은 시험으로 잘 안 잡힌다. 내 일에 맞는 **내 시험**을 만드는 것이 쓰는 쪽의 몫이다.

작은 모델도 생각한다: 큰 모델의 풀이 과정을 작은 모델에 가르치는 것도 파인튜닝이다 — 데이터가 "답" 대신 "풀이"일 뿐. 오늘 배운 방법의 연장선.

출처: Stanford HAI, AI Index Report 2026, Technical Performance.

한계: 지어내고, 잊고, 바닥난다

```
Q: 퇴직금은 어떻게 계산하나요?
A: 제30조에 따라 퇴직일로부터 30일 이내에 퇴직수당을 지급합니다.
----------------------------------------------
--------------------------
Q: 민트상사 대표이사는 누구인가요?
A: 제5조에 따라 대표이사는 사내 이사회가 선임합니다.
----------------------------------------------
--------------------------
```

오늘 셀 7(T4 실측): 없는 조항을 번호까지 붙여 지어냈다



도서관 서가 — 사람이 쓴 공개 글은 유한하다

지어낸다

모르면 그럴듯하게 만든다(환각). 시험 문제 자체도 2∼42%가 틀려 있어 점수로는 안 잡힌다

잊는다

긴 글의 **중간**에 있는 정보를 잘 놓친다("lost in the middle"). 창이 100만 토큰이어도 읽는 것과 쓰는 것은 다르다

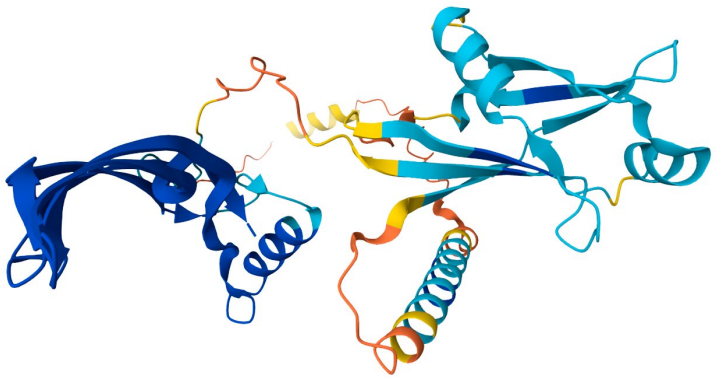
바닥난다

공개된 사람 글은 2026∼2032년 사이 다 쓸 것으로 추정(Epoch AI). 다음 데이터는 합성 데이터와 **조직 안의 데이터**

한계가 곧 일거리다. 환각엔 근거 붙이기(RAG)와 내 시험, 망각엔 문서 쪼개기, 데이터 고갈엔 **우리 데이터** — 전부 오늘 한 것.

출처: Stanford AI Index 2026(문항 오류 2∼42%) · Liu et al., Lost in the Middle(2023) · Epoch AI(2024-06). 사진: UIUC 도서관 서가, Chevsapher, CC0.

AI가 발견한다: 단백질에서 알고리즘까지



AlphaFold가 예측한 단백질 구조 — 2억 개 공개

2024년 노벨상 둘

물리학 Hopfield · Hinton: 신경망(4차시 다이얼)의 기초. **화학** Baker · Hassabis · Jumper: 단백질 구조를 예측하는 AlphaFold. 실험으로 몇 년 걸리던 일을 몇 분에.

2025∼ AlphaEvolve

AlphaEvolve(2025-05): LLM이 알고리즘 후보를 쓰고 프로그램이 채점하는 되먹임. 4×4 복소 행렬 곱셈 48회(1969년 Strassen 49회 이후 56년 만), 구글 계산 자원 0.7% 회수. 같은 해 AI co-scientist는 세균 바이러스의 전파 가설을 48시간에 내놓았고 실험으로 확인됐다(Cell, 2025).

발견의 공통 모양: 모델이 **후보**를 많이 내고, 사람이 만든 **검증 장치**(실험 · 채점 프로그램 · 시험)가 거른다. 검증 장치는 그 분야 사람이 만든다 — 오늘의 "내 시험"과 같은 자리.

출처: 노벨상 위원회 2024 · Google DeepMind 블로그 2025-05 · Cell 2025. 그림: AlphaFold DB, GDF15, 퍼블릭 도메인.

일한다: 에이전트, 그리고 열린 모델

에이전트

컴퓨터 화면을 보고 클릭하고 파일을 고치는 "일하는 AI". 컴퓨터 사용 시험 OSWorld에서 1년 새 12%에서 66%로(사람 72%). 도구를 꽂는 공통 규격(MCP)이 자리 잡아, 2차시의 "스킬"이 그 입구였다.

열린 모델 vs 닫힌 모델

2026년 3월 기준 최고 닫힌 모델이 최고 공개 모델을 **3.3%** 앞선다(2024년 8월엔 0.5%). 차이는 있지만 공개 모델이 1년 전 최고와 같다. 한국어 공개 모델도 여럿(오늘의 Kanana 등).

에이전트 안의 작은 모델

에이전트는 한 일을 하려고 모델을 **수십 번** 부른다 — 분류, 추출, 도구 고르기, 형식 맞추기. 이 잦은 호출은 작고 빠르고 싼 모델의 몫이 되고 있고, 그 모델은 **그 일에 맞게 파인튜닝**된다. 오늘 만든 "형식을 지키는 2B"가 바로 그런 부품이다.

일하게 하려면

권한(무엇을 클릭해도 되나), 기록(무엇을 했나), 되돌리기(틀리면). 7차시 AI 보안에서 다룬다.

출처: Stanford HAI, AI Index Report 2026 (OSWorld, 공개 · 비공개 격차).

그래서 우리는: 오늘 배운 것의 자리



작은 공개 모델

내려받아 내 서버에서. 자료가 밖으로 안 나간다. 1년 전 최고 수준



+ 내 데이터 (파인튜닝)

말투 · 형식 · 절차. 수백 쌍 · 몇 분. 어댑터 수십 MB



+ 내 문서 (RAG)

사실 · 숫자 · 최신. 파일 교체로 갱신. 출처 표시

★ 한 줄

모델은 계속 작아지고 싸지고 똑똑해진다 — 그것은 남이 해 준다. 남지 않는 것은 **우리 데이터**(무엇을 가르칠지), **우리 문서**(무엇을 찾게 할지), **우리 시험**(잘했는지 어떻게 알지)이다. 3 · 4 · 5 · 6차시가 전부 이 세 가지를 만드는 연습이었다.

⚠ 신중할 것 셋

환각은 작아진 모델에서 더 흔하다(오늘 셀 7). **학습 데이터는 모델에 남는다**(준비 원칙). **평가 없는 배포는 없다**(시험용 질문 묶음). 셋 다 도구가 아니라 쓰는 사람의 일이다.

오늘의 핵심 정리

6차시에서 배운 것

1. **파인튜닝 = 사전학습된 공개 모델에 내 예시로 짧은 학습.** 사전학습은 남이, 미세조정은 우리가 한다
2. **LoRA**: 원래 다이얼은 잠그고 보조 다이얼(약 1%)만 돌린다. 결과는 수십 MB 어댑터. 큰 모델은 4비트로 압축(QLoRA)
3. **데이터 = 질문-답 쌍.** 모양을 통일하고, 표현을 다양하게, 틀린 답 없이, 시험용은 남긴다. 최소 100, 1,000부터 안정. 품질 $>$ 양
4. **학습 설정**은 기본값(2e-4 · r 16 · 1∼3 에포크)에서 하나씩. 손실이 0.2 아래면 외우는 중. 손실은 시험 점수가 아니다
5. **잘하는 일과 못하는 일**: 말투 · 형식 · 절차는 확실히 배운다. 낱낱의 사실은 반쯤, 모르면 지어낸다 — RAG를 붙여도. 사실은 RAG에, "없다"는 데이터에
6. **고르는 순서**: 프롬프트 $\rightarrow$ RAG $\rightarrow$ 파인튜닝. 둘을 합친다(셀 8). 모델은 작아지고 싸진다 — 남는 것은 데이터 · 문서 · 시험

★ Big Picture

3차시 표의 첫째 길을 오늘 걸었다. "예시를 보여 주면 다이얼이 맞춰진다"(4차시)를 사진(5차시)에 이어 글로 했고, 그 끝에서 셋째 길(RAG)과 다시 만났다.

집에서 이어하기

`prompts/00_README.txt` — 실습 파일 목록과 공통 규칙, `prompts/12_home.txt` — 집에서 하는 순서

1. 내 FAQ 100쌍

가상의 조직 하나를 정해 자주 받는 질문 10가지, 표현 10개씩. 답 모양은 하나로. "없는 질문 → 없습니다" 쌍도 10개. 10쌍은 시험용으로 뺀다

2. JSONL로 셀 3에

`docs/data/` 파일 모양대로. 12_home.txt의 "셀 3 바꾸는 법" 대로 `SERVICE`를 내 데이터로

3. 학습 · 시험 · 비교

셀 5 학습, 시험용 10쌍으로 전후 비교. `EPOCHS` 1 · 3 · 5로 손실과 답이 어떻게 달라지나

한 바퀴의 완료 기준

시험용 10쌍에서 학습 전 · 후 답 표 하나, 손실 그래프 하나, 어댑터 zip 하나. 그리고 "모르는 질문 3개"에 모델이 뭐라 했는지 한 줄. 잘 안 되면 설정보다 **데이터의 모양과 표현 수**를 먼저 본다.

모든 실습은 개인 계정 · 가상 데이터로. 실제 민원 · 실명 · 업무 규정은 쓰지 않는다. 더 큰 모델은 `load_in_4bit=True`로.

PC 정리 (공용 PC에서 나가기)

나가기 전 다섯 줄

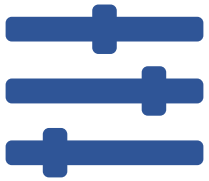
1) 셀 9로 `mint_lora.zip`을 내려받고 USB · Drive로 옮겼다 (노트북 자체는 Drive에 자동 저장)
2) 기록표(prompts의 O/X 표)를 사진으로 남겼다
3) Colab 메뉴 **런타임** → **런타임 연결 해제 및 삭제** (GPU 반납)
4) Google 로그아웃 (오른쪽 위 프로필 → 로그아웃), 브라우저 "비밀번호 저장"은 거절했는지 확인
5) 내려받기 폴더와 바탕화면의 zip 파일 삭제

Drive에 남는 것

노트북(코드와 출력 글). 학습한 어댑터 `mint_lora`는 Colab 서버 쪽에 있어 **세션이 끝나면 사라진다** — 그래서 셀 9가 있다.

GPU 한도

무료 Colab은 GPU 사용 시간에 한도가 있다. 쓰지 않을 때 연결을 끊어 두면 다음에 받기 쉽다.



군-학 연계 프로그램 범용 교육

6차시 sLLM 파인튜닝 — 작은 공개 LLM을 내 데이터로 학습시키기

서왕덕 경기대학교 AI컴퓨터공학부